

AI-TECH

Przykład 3 DO LABORATORIUM 1 z UCZENIA MASZYNOWEGO

Regresja liniowa i logistyczna

Tomasz Neumann

Regresja wielomianowa

Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego Program Operacyjny Polska Cyfrowa na lata 2014-2020,
Oś Priorytetowa nr 3 "Cyfrowe kompetencje społeczeństwa" Działanie nr 3.2
"Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej" Tytuł projektu: „Akademia
Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”

1. Przykład 3

W tym przykładzie zostaną przeanalizowane dane, które nie mają trendu liniowego. Okazuje się jednak, że mając model liniowy można tego dokonać na tego typie danych wejściowych poprzez dodanie potęg każdej cechy w postaci nowej cechy i poddaniu treningowi takiego zestawu cech - jest to regresja wielomianowa (polynomial regression). Na podstawie biblioteki Scikit-Learn i klasy PolynomialFeatures można przeanalizować zmianę położenia w czasie ciała wyrzuconego do góry z prędkością początkową 23 m/s z wysokości 8 m nad powierzchnią Ziemi. Rozpoczynamy jak poprzednio od importu potrzebnych bibliotek


```
In [1]: # Import podstawowych bibliotek języka Python
import numpy as np # operacje numeryczne
import matplotlib # wykresy i ich ustawienia
import matplotlib.pyplot as plt # tworzenie wykresu
```

oraz wygenerowania odpowiednich danych do zakładanego przypadku oraz ich wizualizację.

```
In [2]: dataset_training_size = 500
t = x_t = np.linspace(0, 5, dataset_training_size).astype(np.float32)
noise = 2*np.random.rand(dataset_training_size).astype(np.float32)
#y = h0+v0*t-0.5*g*t^2
h0 = 8.0
v0 = 23
g = 9.81

y=h0+v0*t-0.5*g*t**2+noise

# Wizualizacja wygenerowanych danych
# Ustawienia związane z wyświetlaniem
matplotlib.rcParams.update({'font.size': 14})
f = plt.figure(figsize=(10, 5), dpi=64)
f1 = f.add_subplot(111)
f1.set_xlabel('t [s]')
f1.set_ylabel('y [m]')
f1.plot(t,y, "k")
plt.show()
```



Następnie należy zaimportować klasę *PolynomialFeatures* oraz stworzyć jej obiekt, podając jako argument stopień wielomianu. Na tym etapie należy zadbać o odpowiednie przygotowanie formatu danych wejściowych oraz odpowiednie przekształcenie cech. Mając to wszystko zrealizowane prawidłowo, można wywołać metodę regresji liniowej, która była wykorzystywana w przykładzie 1.

```
In [3]: from sklearn.preprocessing import PolynomialFeatures
poly_features = PolynomialFeatures(degree=2, include_bias=False)
t = t.reshape(dataset_training_size,1)
y = y.reshape(dataset_training_size,1)
t_poly = poly_features.fit_transform(t) #obiekt ten zawiera teraz oryginalną cec

from sklearn.linear_model import LinearRegression
lin_reg = LinearRegression()
lin_reg.fit(t_poly, y)
print(lin_reg.intercept_, lin_reg.coef_)
```

```
[8.987614] [[23.019447 -4.91206 ]]
```

Uzyskane wartości współczynników można porównać z tymi z założeń początkowych.

Zadania do wykonania

Zadanie 1

- W jaki sposób zaszumienie będzie wpływało na wartości wyznaczanych parametrów? Sprawdź wpływ dopasowania wielomianów wyższych stopni do tych danych.
- Wykorzystaj klasę *PolynomialFeatures* do wyuczenia współczynników dla wielomianu trzeciego stopnia. Przedstaw dane rzeczywiste oraz te wyuczone z modelu na jednym rysunku.

