

AI – TECH

SKRYPT DO LABORATORIUM

UCZENIE MASZYNOWE

LABORATORIUM 1:

Regresja liniowa i logistyczna

dr Tomasz Neumann



Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



1. Opis ćwiczenia

Wymagania wstępne:

Osiągnięcie celów ćwiczenia będzie możliwe poprzez właściwe przygotowanie się studenta do zajęć.

Będzie to możliwe poprzez:

- powtórzenie wiedzy nabytej w czasie wykładów,
- zapoznanie się (przed ćwiczeniem) z instrukcją do ćwiczenia ilustrującą podstawowe zagadnienia z zakresu tematyki ćwiczenia.

Ponadto wymagana jest od studenta:

- podstawowa umiejętność programowania,
- podstawowa znajomość języka Python,
- podstawowa znajomość analizy danych,
- umiejętność twórczego myślenia.

Wyżej wymienione wymagania bazują na wiedzy i umiejętności jakie studenci powinni zdobyć w czasie edukacji na I poziomie studiów jak i w ramach przedmiotu „Języki programowania dla sztucznej inteligencji”. W przeciwnym przypadku studenci powinni nadrobić samodzielnie stosowny materiał.

Stanowisko laboratoryjne powinno być wyposażone w komputer z dostępem do sieci komputerowej oraz z następującymi zasobami:

- przykładowe programy (kody programów) podane w załączniku,
- zainstalowany interpreter języka Python w wersji co najmniej 3.6 z możliwością doinstalowania bibliotek standardowych za pomocą pip lub anaconda (najlepiej w ramach dedykowanego środowiska wirtualnego),
- zainstalowaną platformę Jupyter Notebook,
- dostęp do rozwiązywania chmurowego Google Colab,
- inne: przeglądarka WWW.

Na komputerze dostępne powinny być zainstalowana instrukcja do ćwiczenia w wersji elektronicznej oraz pliki testowe. Przed zajęciami stacjonarnymi, prowadzący powinien sprawdzić czy dostępne są na stanowisku wymagane zasoby i programy.

Cele ćwiczenia:

Celem ćwiczenia jest praktyczna demonstracja wiedzy teoretycznej, przedstawionej w ramach wykładów. Realizując ćwiczenie laboratoryjne studenci zdobędą szereg nowych umiejętności w zakresie stosowania modelu regresji liniowej oraz regresji logistycznej jak i interpretacji uzyskanych wyników w typowych problemach uczenia maszynowego.

Spodziewane efekty kształcenia - umiejętności i kompetencje:

Student po zajęciach laboratoryjnych będzie posiadał umiejętność przygotowania danych oraz zastosowanie do nich metody regresji liniowej bądź regresji logistycznej oraz będzie w stanie zinterpretować uzyskane wyniki w standardowych problemach uczenia maszynowego.

Metody dydaktyczne:

Student w pierwszej kolejności realizuje zadania przykładowe podczas których przygotowuje odpowiednie środowisko programistyczne, poprzez które testuje poszczególne elementy pracy z danymi do których można wykorzystać metodę regresji liniowej lub regresji logistycznej. Następnie, na podstawie posiadanej wiedzy i zdobytej umiejętności z zadań demonstracyjnych, realizuje przydzielone zadania. Wszystkie kody źródłowe programów wpisuje w dokumencie elektronicznym (oraz pokazuje prowadzącemu podczas ich realizacji), który jednocześnie staje się sprawozdaniem z ćwiczenia laboratoryjnego.

Materiały wprowadzające i pomocnicze:

- Python – dokumentacja języka <https://docs.python.org/pl/3/>
- SciKit-Learn – dokumentacja do podstawowej biblioteki uczenia maszynowego stosowanej w języku Python: <https://scikit-learn.org/stable/tutorial/basic/tutorial.html>
- Statsmodels – dokumentacja do modułu języka Python, dająca opis klas i funkcji do estymacji wielu modeli statystycznych, a także do przeprowadzania testów statystycznych i eksploracji danych.

- Jupiter notebook – narzędzie ułatwiające implementację kodu, uruchamianie oraz testowanie:
<https://realpython.com/jupyter-notebook-introduction/>
- Google Colab – narzędzie umożliwiające pracę z kodem w notebooku Jupiter oraz jego uruchamianie w chmurze (konieczność posiadania konta Google):
<https://colab.research.google.com/github/cs231n/cs231n.github.io/blob/master/python-colab.ipynb>

Zasady oceniania/warunek zaliczenia ćwiczenia

Ocenie podlegać będzie realizacja poszczególnych zadań w ramach danego ćwiczenia laboratoryjnego. Dodatkowo w czasie realizacji ćwiczenia przydzielone zostaną studentowi dodatkowe zadania. Poszczególnym zadaniom przydzielono liczbę punktów jakie można zdobyć za ich wykonanie. Maksymalna liczba punktów wynosi 10.

Wykaz literatury podstawowej do ćwiczenia:

1.	Materiały z wykładu do przedmiotu „Języki programowania dla sztucznej inteligencji”
2.	Materiały z wykładu do przedmiotu „Uczenie maszynowe”
3.	Marcin Szeliga, Praktyczne uczenie maszynowe, PWN 2019
4.	M. Gagolewski, M. Bartoszek, A. Cena, Przetwarzanie i analiza danych w języku Python, PWN, 2016
5.	Sebastian Raschka, Python. Uczenie maszynowe, Helion 2017

2. Przebieg ćwiczenia

L.p.	Zadanie
1.	Zapoznanie się z instrukcją laboratoryjną (przed ćwiczeniem)
2.	Wprowadzenie kierownika ćwiczenia. Zapoznanie się uczestników ze stosowanymi programami, przegląd dokumentacji (5 min.)
3.	Zagadnienie regresji liniowej – przykłady rozwiązania (20 min.)
4.	Metoda gradientu prostego (15 min.)
5.	Regresja wielomianowa (20 min.)
6.	Regresja logistyczna w scikit-learn (25 min.)
7.	Regresja logistyczna w StatsModels (25 min.)
8.	Regresja logistyczna – wykorzystanie danych z MNIST i tensorflow (20 min.)
9.	Przesłanie/pokazanie zbioru dokumentów/programów do oceny (5 min.)

Uwagi

PRZED przystąpieniem do ćwiczenia należy utworzyć własny, unikalny katalog w lokalizacji wskazanej przez prowadzącego, a następnie należy tam umieścić pliki testowe oraz własne implementacje kodu programów dokonujących rozwiązanie zadanie. Należy pracować wyłącznie na wykonanej kopii plików.

3. Wprowadzenie do ćwiczenia

Uczenie maszynowe można określić jako uczenie maszyn na podstawie przykładów. Tak wyuczone maszyny mogą dostarczać nam nowe dane, inne od treningowych, w celu uzupełnienia zbioru brakujących danych. Takie podejście pozwala także rozwiązywać problemy, które z punktu widzenia algorytmicznego, nie dałoby się go w jednoznaczny sposób zaimplementować i rozwiązać (np. proces rozpoznawania obrazów przez maszyny).

Metody uczenia maszynowego powinniśmy wybrać do rozwiązania problemów, gdy:

- nie umiemy rozwiązać problemu (ale wiemy, że istnieje rozwiązanie problemu);
- rozwiązania szybko zmieniają się;
- rozwiązania muszą być dostosowane do poszczególnych użytkowników.

Jednym z kryteriów podziału technik uczenia maszynowego jest rodzaj postawianej hipotezy, gdzie wyróżniamy modele regresji oraz modele partycjonujące. W tych ostatnich hipoteza ma postać reguł dzielących przykłady, co będzie omawiane w ramach kolejnych zajęć laboratoryjnych. W przypadku modeli regresji, na którym skupimy się w obecnym ćwiczeniu, hipoteza ma postać funkcji, a proces uczenia polega na znalezieniu optymalnych wartości parametrów tej funkcji. Hipoteza jest tym lepsza, im jest bliższa prawdziwej funkcji zmiennej wyjściowej do zmiennych wejściowych.

W ramach tego ćwiczenia zostaną przedstawione przykłady oraz zadania do samodzielnego rozwiązania z:

- predykcji za pomocą metody regresji liniowej przy użyciu rozwiązania równania normalnego jak i wykorzystując gotowe implementacje w pakiecie scikit-learn oraz statsmodels,
- użycia prostej implementacji metody gradientu prostego w celu uzyskania rozwiązania problemu przy różnych parametrach współczynnika szkolenia jak i zastosowania funkcji kosztu,
- wykorzystanie regresji liniowej do danych, które nie charakteryzują się zależnością liniową (regresja wielomianowa),
- wprowadzenia do zagadnienia regresji logistycznej oraz możliwości modelu w pakietach scikit-learn oraz statsmodels przy użyciu danych syntetycznych jak i z rzeczywistych pomiarów badań oraz opisów,
- wykorzystania regresji logistycznej do klasyfikacji cyfr ze zbioru MNIST.

Szczegółowe opisy oraz poszczególne moduły kodów zostały umieszczone w skryptach Jupyter Notebook, które są nierozłącznym elementem instrukcji do tego ćwiczenia laboratoryjnego (lista plików w dodatku).

4. Forma i zawartość sprawozdania

Ocenie podlegać będzie realizacja poszczególnych zadań w ramach danego ćwiczenia laboratoryjnego. Dodatkowo w czasie realizacji ćwiczenia przydzielone zostaną studentowi dodatkowe zadania. Poszczególnym zadaniom przydzielono liczbę punktów jakie można zdobyć za ich wykonania. Maksymalna liczba punktów wynosi 10.

Dodatki:

Pliki instruktażowe oraz pliki z zdanymi niezbędne do wykonania ćwiczenia laboratoryjnego:

- 1) *lab1_ex01.ipynb*
- 2) *lab1_ex02.ipynb*
- 3) *lab1_ex03.ipynb*
- 4) *lab1_ex04.ipynb*
- 5) *lab1_ex05.ipynb*
- 6) *diabetes.csv*
- 7) *lab1_ex06.ipynb*