



POLITECHNIKA
GDAŃSKA

AI TECH



Uczenie maszynowe

Wykład 4

Jacek Rumiński

Katedra Inżynierii Biomedycznej, Wydział ETI



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska

Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego

Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.

Plan wykładu:

- **Wprowadzenie**
- Selekcja cech – metoda zysku informacji i podobne
- Selekcja cech – testy statystyczne
- Podsumowanie

Selekcja cech

Selekcja cech jest jedna z form redukcji danych, mającą na celu

- poprawę efektywności obliczeniowej (mniej danych)
- poprawę właściwości generalizujących (uogólniających) modelu
- uproszczenie modelu (zwiększenie właściwości wyjaśniających, brzytwa Ockhama)
- itd.

Selekcja cech

Często stosowane metody selekcji cech bazują na:

- miarach jednorodności wartości cech (np. entropia, indeks Gini)
- testach statystycznych (t-test, F-test)
- modelach uogólniających dane (klasyfikacyjne, regresyjne) – np. drzewa decyzyjne
- modelach uogólniających dane z uwzględnieniem regularyzacji funkcji kosztu
- itd.

Typowe strategie (heurystyczne) to selekcja krokowa, krokowa eliminacja wsteczna, wybór K cech, itp.

Plan wykładu:

- Wprowadzenie
- **Selekcja cech - metoda zysku informacji i podobne**
- Selekcja cech - testy statystyczne
- Podsumowanie

Selekcja cech - entropia vs. entropia krzyżowa

Na wcześniejszych wykładach przedstawiliśmy entropię jako miarę ilości informacji w zbiorze danych. Entropia (informacji) zastosowana w teorii informacji (Shannon, 1948) wskazywała ile średnio bitów (stąd logarytm o podstawie 2) potrzebujemy do zakodowania symboli:

$$H(p) = - \sum_{k=0}^{K-1} p(k) \cdot \log_2(p(k))$$

Założmy sytuację, że mamy dwa rozkłady prawdopodobieństwa związane z tym samym eksperymentem: prawdziwy rozkład (referencja) prawdopodobieństwa p oraz rozkład uzyskany dla opracowanego modelu (estymowany) q . Wówczas możemy porównać te dwa rozkłady za pomocą entropii krzyżowej (ang. cross entropy):

$$H(p, q) = H(p) - D_{KL}(p||q)$$

gdzie:

$D_{KL}(p||q)$ - to dywergencja Kullbacka-Leiblera (czy inaczej entropia względna).

Selekcja cech - entropia vs. entropia krzyżowa

Entropia krzyżowa w takim przypadku może być również wyrażona wzorem:

$$H(p, q) = - \sum_{k=0}^{K-1} p(k) \cdot \log_2 (q(k))$$

i dlatego dywergencję można także zapisać jako:

$$D_{KL}(p||q) = - \sum_{k=0}^{K-1} p(k) \cdot \log_2 \left(\frac{q(k)}{p(k)} \right)$$

Dywergencja jest miarą podobieństwa między dwoma rozkładami i nazywana jest czasami miarą odległości (ale metryką odległości nie jest ze względu na brak symetrii).

Selekcja cech - entropia vs. entropia krzyżowa

Zarówno entropia krzyżowa jak i dywergencja mogą być wykorzystywane do porównywania dwóch rozkładów. W praktyce, bardzo często wykorzystuje się entropię krzyżową jako funkcję kosztu do uczenia modeli klasyfikacji danych (zwłaszcza w problemie dwuklasowym).

Założmy, że mamy dwie klasy: **C0** i **C1** (np. „jest choroba” i „nie ma choroby” albo „pies” czy „kot”).

1. Dla danego zbioru testowego jesteśmy w stanie wyznaczyć rozkład prawdopodobieństwa.

Założmy, że uzyskaliśmy: **$P(Y=C0)=0,1$** i **$P(Y=C1)=0,9$** .

Selekcja cech - entropia vs. entropia krzyżowa

2. Następnie w wyniku uczenia maszynowego otrzymaliśmy model M. Stosując ten model do predykcji dla obserwacji X uzyskaliśmy rozkład prawdopodobieństwa estymowanych klas:

a) $Q(Y=C0)=0,1$ i $Q(Y=C1)=0,9$, to wówczas

$$H(p, q) = - \sum_{k=C0}^{C1} p(k) \cdot \log_2(q(k)) = -p(C0) \cdot \log_2(q(C0)) - p(C1) \cdot \log_2(q(C1))$$

$$H(p, q) = -0,1 \cdot \log_2(0,1) - 0,9 \cdot \log_2(0,9) = 0,469$$

b) $Q(Y=C0)=0,9$ i $Q(Y=C1)=0,1$, to wówczas

$$H(p, q) = -0,1 \cdot \log_2(0,9) - 0,9 \cdot \log_2(0,1) = 3,005$$

Mniejsza wartość entropi krzyżowej oznacza większe podobieństwo rozkładów prawdopodobieństw.

Selekcja cech - entropia vs. entropia krzyżowa

Powróćmy teraz do dywergencji Kullbacka-Leiblera.

Założmy, że zmienna losowa A związana jest z atrybutem, który może przyjmować określone wartości. Natomiast zmienna losowa Y z etykietami klas. Możemy wówczas zastanowić się nad zależnością etykiet klas od wartości atrybutów, czyli rozważać prawdopodobieństwa **$P(A=a, Y=y)$** = **$p(a,y)$** (zmienna losowa A przyjmie wartość a i zmienna losowa Y przyjmie wartość y).

Zbadajmy następnie następujący iloraz:

$$\frac{p(a, y)}{p(a)p(y)}$$

zauważmy, że jeśli zdarzenia są niezależne to **$p(a,y)=p(a)p(y)$** , czyli iloraz będzie miał wartość 1. Logarytm z takiej wartości miałby wartość 0.

Dlaczego jest to ważne? Jeżeli cecha nie jest powiązana z etykieta klasy wówczas nie różnicuje klasy.

Selekcja cech - entropia vs. entropia krzyżowa

Uzyskany logarytm:

$$\log_2 \frac{p(a, y)}{p(a)p(y)}$$

pomnóżmy przez wartość **$p(a, y)$** i sumujmy po wszystkich wartościach zmiennych losowych A i Y (czyli możliwych wartościach atrybutów i etykiet klas):

$$\sum_{a, y} p(a, y) \log_2 \frac{p(a, y)}{p(a)p(y)}$$

Pamiętamy, że

$$D_{KL}(p||q) = - \sum_k p(k) \cdot \log_2 \left(\frac{q(k)}{p(k)} \right) = \sum_k p(k) \cdot \log_2 \left(\frac{p(k)}{q(k)} \right)$$

Czyli:

$$D_{KL}(P(A, Y)||P(A)P(Y)) = \sum_{a, y} p(a, y) \log_2 \frac{p(a, y)}{p(a)p(y)}$$

Selekcja cech - entropia vs. entropia krzyżowa

Można dalej wykazać, że:

$$D_{KL}(P(A, Y) || P(A)P(Y)) = \sum_{a,y} p(a, y) \log_2 \frac{p(a, y)}{p(a)p(y)} = \sum_{a,y} p(a, y) \log_2 \frac{p(y|a)p(a)}{p(y)p(a)} =$$

$$\begin{aligned} \sum_{a,y} p(a, y) \log_2 \frac{p(y|a)}{p(y)} &= \sum_{a,y} p(a, y) \log_2 p(y|a) - \sum_{a,y} p(a, y) \log_2 p(y) = \\ \sum_{a,y} p(a, y) \log_2 p(y|a) - \sum_y \left(\sum_a p(a, y) \right) \log_2 p(y) &= \sum_{a,y} p(a, y) \log_2 p(y|a) - \sum_y p(y) \log_2 p(y) = \\ \sum_{a,y} p(a)p(y|a) \log_2 p(y|a) - \sum_y p(y) \log_2 p(y) &= -H(Y|A) + H(Y) = I(A; Y) \end{aligned}$$

Czyli przeszliśmy od dywergencji do różnicy entropii dla zmiennej Y (etykiety klas) i entropii warunkowej dla Y pod warunkiem A (czyli entropii różnicującej rozkład etykiet klas biorąc pod uwagę konkretne wartości atrybutów). Miara ta nosi nazwę informacji wzajemnej.

Selekcja cech - entropia vs. entropia krzyżowa

Informacja wzajemna to:

$$I(A; Y) = D_{KL}(P(A, Y) || P(A)P(Y)) = H(Y) - H(Y|A)$$

Zauważmy, że informacja wzajemna to zmiana entropii pomiędzy stanem bez dodatkowej informacji (tylko Y) i z dodatkową informacją (Y i A).

Dlatego miara ta w eksploracji danych i uczeniu maszynowym nazywana jest czasami miarą zysku informacji i oznaczana jako:

$$IG(Y, A) = H(Y) - H(Y|A)$$

Selekcja cech - zysk informacji

Zysk informacji (informacja wzajemna) umożliwia nam wygenerowanie rankingu dla poszczególnych cech względem etykiety klasy. Po wygenerowaniu rankingu można usunąć atrybuty o najniższej mierze rankingu. Rozpatrzmy przykład:
Mamy zbiór 250 wierszy z zapisem informacji dla studentów 1 i 2 poziomu studiów. Przykładowy podzbiór pokazano poniżej.

gender	specialization	origin	age	evaluation	level
M	machine_learning	domestic	_20	3	1
F	inf_systems	domestic	_20	5	1
F	machine_learning	domestic	_20	3	1
F	data_bases	domestic	20_25	3	1
M	data_bases	international	_20	4	1

Selekcja cech - zysk informacji

Podsumowanie zbioru danych dla studentów II poziomu studiów:

gender	specialization	origin	age	evaluation	#records
M	data_bases	domestic	20-25	4	16
F	data_bases	international	25-30	5	47
M	inf_systems	international	25-30	5	18
M	data_bases	domestic	20-25	5	21
F	inf_systems	domestic	20-25	5	18

Podsumowanie zbioru danych dla studentów I poziomu studiów:

gender	specialization	origin	age	evaluation	#records
M	data_bases	international	_20	4	18
K	machine_learning	domestic	_20	3	20
M	machine_learning	domestic	_20	3	22
K	data_bases	domestic	20-25	3	24
M	inf_systems	international	20-25	4	22
K	inf_systems	domestic	_20	5	24

Selekcja cech - zysk informacji

Dokonajmy obliczeń dla przykładu

$$H(Y) = -\frac{120}{250} \cdot \log_2 \left(\frac{120}{250} \right) - p \left(\frac{130}{250} \right) \cdot \log_2 \left(\frac{130}{250} \right) = 0,9988$$

Obliczmy teraz $H(Y|A)$ dla atrybutu A „specialization”, dla którego są 3 możliwe wartości:

Atrybut specjalność=„data_bases”:	$s_{11}=84$	$s_{21}=42$	$I(s_{11}, s_{21})=0,9183$
Atrybut specjalność=„inf_systems”:	$s_{12}=36$	$s_{22}=46$	$I(s_{12}, s_{22})=0,9892$
Atrybut specjalność=„machine_learning”:	$s_{13}=0$	$s_{23}=42$	$I(s_{13}, s_{23})=0$

gdzie:

s_{11} - liczba studentów II poziomu dla specjalności „BazyDanych”

s_{21} - liczba studentów I poziomu dla specjalności „BazyDanych”

analogicznie dalej.

$$H(Y|A = \text{„specialization”}) = \frac{126}{250} I(s_{11}, s_{21}) + \frac{82}{250} I(s_{12}, s_{22}) + \frac{42}{250} I(s_{13}, s_{23}) = 0,7873$$

Selekcja cech - zysk informacji

Dokonajmy obliczeń dla przykładu:

$$IG(Y, A) = H(Y) - H(Y|A) = 0,9988 - 0,7872 = 0,2115$$

Analogicznie obliczamy dla pozostałych atrybutów otrzymując:

IG(gender)	= 0,0003
IG(origin)	= 0,0407
IG(specialization)	= 0,2115
IG(evaluation)	= 0,4490
IG(age)	= 0,5971

Możemy teraz odrzucić wybrane cechy (o wartości $IG < T$, gdzie T to obrana wartość progowa).

Selekcja cech - inne miary koncentracji

W analogiczny sposób możemy przeprowadzić analizę stosując indeks Gini dla podziału na klasy bez i z użyciem atrybutów.

Przykłady zilustrowano w załączonych interaktywnych notatnikach.

Zauważmy na koniec, że wskazane miary koncentracji bazują na cechach nominalnych lub liczbowych o umiarkowanej dynamice wartości (np. 0 lub 1). W przypadku liczb rzeczywistych (zmiennych ciągłych) uzyskiwane wartości metryk (np. entropii) będą wskazywać duże zróżnicowanie cechy.

Zatem porównując cechę dyskretną (np. etykiety klas) z cechą ciągłą należy, np.:

- poddać dyskretyzacji lub kategoryzacji cechę ciągłą do K przedziałów lub
- wybrać metodę bazującą na sąsiedztwie wartości dla danej cech dyskretnej (np. jak w <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0087357>).

Przykłady praktyczne (notatnik interaktywny ML_04_01_Feature_Selection_Inf.ipynb)

Selekcja cech (zysk informacji itp.) w środowisku Google Colaboratory/ Jupyter Notebook.

https://colab.research.google.com/drive/1GZKI1_BEkq15XYZROrM-O3_Sk68HxBNL?usp=sharing

Plan wykładu:

- Wprowadzenie
- Selekcja cech – metoda zysku informacji i podobne
- **Selekcja cech – testy statystyczne**
- Podsumowanie

Selekcja cech - test statystyczne

W selekcji cech możemy wykorzystać różne statystyki testowe. Najczęściej będą to statystyki t i F.

Wyznaczamy wówczas wartości miar porównujące zróżnicowanie wartości cechy pomiędzy grupami (klasami) w odniesieniu do zróżnicowania w obrębie grup (klas):

$$test = \frac{\text{zróżnicowanie pomiędzy grupami}}{\text{zróżnicowanie w obrębie grup}}$$

Szukamy takich cech, które silnie różnicują grupy, czyli pozwalają osiągnąć wysokie wartości testu.

Selekcja cech - test t

W przypadku zastosowania t-testu do selekcji cech będziemy porównywać najczęściej grupy danych wynikające z podziału na klasy. Załóżmy, że mamy dwie klasy oznaczone jako 0 i 1 oraz jedną cechę, np. wiek. Wówczas jedną grupę stanowią wszystkie wartości cechy dla klasy 0, natomiast drugą grupę tworzą wszystkie wartości cechy dla klasy 1.

$$X = [12, 15, 20, 40]$$

$$y = [0, 0, 1, 1]$$

to

$$X_1 = [12, 15]$$

$$X_2 = [20, 40]$$

Chcemy teraz zbadać, czy wartości średnie X_1 i X_2 są podobne:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\text{mianownik}}$$

gdzie *mianownik* obliczany jest w zależności do charakterystyki grup danych (tj. czy są równe rozmiarem, czy ich wariancje są różne, itd.). W każdym przypadku w mianowniku występuje odniesienie do wariancji w grupach i liczebności grup.

Selekcja cech - test t

Jeśli rozmiary grup (N_1 i N_2) mogą być różne oraz wariancje dla grup są podobne ($0,5 < s_{X1}/s_{X2} < 2$) to wówczas:

$$\text{mianownik} = s_n \cdot \sqrt{\frac{1}{N_1} + \frac{1}{N_2}}, \quad s_n = \sqrt{\frac{(N_1-1)s_{X1}^2 + (N_2-1)s_{X2}^2}{N_1 + N_2 - 2}}$$

Liczba stopni swobody, $dof = N_1 + N_2 - 2$.

Jeśli rozmiary grup (N_1 i N_2) mogą być różne oraz wariancje dla grup są znacznie różne (np. $s_{X1}/s_{X2} > 2$) to wówczas (Welch's t-test):

$$\text{mianownik} = \sqrt{\frac{s_{X1}^2}{N_1} + \frac{s_{X2}^2}{N_2}}, \quad dof = \frac{(s_{n1} + s_{n2})^2}{\frac{s_{n1}^2}{N_1 - 1} + \frac{s_{n2}^2}{N_2 - 1}}, \quad s_{n1} = \frac{s_{X1}^2}{N_1}, \quad s_{n2} = \frac{s_{X2}^2}{N_2}$$

Selekcja cech - test t

Jeżeli $t=0$ to obie średnie są takie same. Jeśli jak $|t|>0$ to w zależności od wartości t , wartości średnie są bardziej lub mniej podobne.

Możemy postawić hipotezę zerową: wartości średnie są takie same.

Następnie porównujemy obliczoną wartość t z rozkładem Studenta (t) sprawdzając, czy dla danej wartości t zależność jaka wynika z naszej próby jest przypadkowa czy nie. Z rozkładu prawdopodobieństwa odczytujemy wartość prawdopodobieństwa dla podanej wartości t .

Jeśli uzyskana wartość prawdopodobieństwa testowego (p -value, p -wartość) jest bardzo duża, np. 0,95 (albo 95%) oznacza to, że nie możemy odrzucić hipotezy zerowej (podobne wartości średnie). Oznacza to, że prawdopodobieństwo uzyskania danej wartości t (lub większej) próbując naszą populację jest 0,95 (95%).



Jeśli natomiast, nasze prawdopodobieństwo jest niewielkie (np. mniejsze niż 0,05 czy 5%, znajdujemy się w ogonie/ogonach rozkładu t) wówczas odrzucamy hipotezę zerową - wartości średnie istotnie się różnią.

Selekcja cech: t-value i p-value

Jeśli wartości średnie X_1 i X_2 są takie same (czy bardzo podobne) to zakładamy, że analizowana cecha nie różnicuje obserwacji ze względu na klasy.

Wartość t (t-value) możemy wykorzystać do utworzenia rankingu cech i wybrać te cechy, które charakteryzują się wysokimi wartościami t .

Możemy wykorzystać także wartości p-value, których małe wartości (np. dla wskazanej wartości referencyjnej np. 5%) wskazują, że wartości średnie nie są podobne, zatem dana cecha bardziej różnicuje klasy.



Selekcja cech: t-value i p-value

Dane są dwa przykładowe zbiory danych. W przykładzie nr 1 wartości cechy nie są bardzo zróżnicowane względem wartości klasy. W drugim przykładzie zróżnicowanie jest większe.

Dla przykładu 1:

- Relacja pomiędzy odchyleniami standardowymi wynosi 1,24, czyli wartości są podobne dla obu grup
- Wartość t-value=0,17, a wartość p-value=0,868

Wniosek: nie można odrzucić hipotezy zerowej. Wartości średnie są podobne. Cecha nie różnicuje wartości klasy.

Dla przykładu 2:

- Relacja pomiędzy odchyleniami standardowymi wynosi 1, czyli wartości są takie same dla obu grup
- Wartość t-value=-9,258, a wartość p-value=0,0000032

Wniosek: można odrzucić hipotezę zerową. Wartości średnie nie są podobne. Cecha różnicuje wartości klasy.

Przykład 1

cecha	klasa
1	0
1	1
2	0
3	1
3	0
4	1
4	0
5	1
5	0
4	1
6	0
5	1

Przykład 2

cecha	klasa
1	0
11	1
2	0
12	1
3	0
13	1
4	0
14	1
5	0
15	1
6	0
16	1

Selekcja cech: t-value i p-value

Przykład – parametry wyniku analizy obrazów z biopsji guzów piersi:

[https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+\(Diagnostic\)](https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+(Diagnostic))

W zbiorze znajduje się 569 wierszy (obserwacji), każdy zawiera wartości dla 30 cech. Etykieta klasy (target) wskazuje, czy opisana obserwacja to zmiana złośliwa (0) czy łagodna (1). Poniżej pokazano podzbiór danych.

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points	mean symmetry	mean fractal dimension
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.30010	0.14710	0.2419	0.07871
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.08690	0.07017	0.1812	0.05667
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.19740	0.12790	0.2069	0.05999
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.24140	0.10520	0.2597	0.09744
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.19800	0.10430	0.1809	0.05883

Selekcja cech - t-value i p-value - zbiór Breast Cancer

Porównajmy wyniki analizy dla dwóch wybranych cech: „worst texture” (index 21) oraz „mean fractal dimension” (index 9). W wyniku przeprowadzonej analizy uzyskamy:

Wybrana cecha: worst texture

Relacja odchyłeń standardowych pomiędzy grupami: 0,989

t-value = 12,231

p-value = 1,078e-30

Wybrana cecha: mean fractal dimension

Relacja odchyłeń standardowych pomiędzy grupami: 1,122

t-value = -0,306

p-value = 0,76

Z porównania można wskazać, że cecha „mean fractal dimension” (index 9) nie różnicuje grup ze względu na klasę. Analogiczną analizę można przeprowadzić dla wszystkich cech i posortować wyniki, następnie wybrać cechy na podstawie progu (dla t-value, p-value) lub wybrać K cech.

Selekcja cech - test F

Jeśli mamy więcej niż 2 klasy, możemy zastosować statystykę F w jednoczynnikowej analizie wariancji (ang. one-way analysis of variance: **one-way ANOVA**).

Analogicznie jak dla testu t będziemy poszukiwać wartości:

$$test = \frac{\text{zróżnicowanie pomiędzy grupami}}{\text{zróżnicowanie w obrębie grup}} = \frac{MS_b}{MS_w}$$

gdzie:

- MS_b - to znormalizowana suma kwadratów z różnic pomiędzy wartościami średnimi każdej grupy względem wartości średniej całego zbioru,
- MS_w - to znormalizowana suma kwadratów różnicy każdej wartości względem wartości średniej danej grupy.

Selekcja cech - test F

Założmy, że mamy 3 klasy. Wówczas dla wybranej cechy uzyskamy trzy grupy (zakładamy, że są próbki dla każdej z klas): X_1, X_2, X_3 .

W celu obliczenia MS_b wyznaczamy:

- wartość średnią $\bar{X}$
- wartości średnie każdej grupy $\bar{X}_1, \bar{X}_2, \bar{X}_3$
- liczebność zbioru i każdej z grup: N, N_1, N_2, N_3
- liczbę stopni swobody $dof=L-1$, gdzie L to liczba grup, tutaj 3

$$MS_b = N_1(\bar{X}_1 - \bar{X})^2 + N_2(\bar{X}_2 - \bar{X})^2 + N_3(\bar{X}_3 - \bar{X})^2$$

$$MS_b = MS_b / dof$$

Selekcja cech - test F

W celu obliczenia MS_w wyznaczamy:

- różnicę wartości danej próbki i wartości średniej grupy do której należy, np. $D_1[0] = X_1[0] - \bar{X}_1$
- sumę kwadratów powyższych różnic np. $S_b = D_1[0]^2 + D_1[1]^2 + D_1[2]^2 + \dots + D_3[k]^2$
- liczbę stopni swobody $dof = L(N-1)$, gdzie L to liczba grup, tutaj 3

$$MS_w = S_b / dof$$

Wartość statystyki F otrzymujemy jako:

$$F = \frac{MS_b}{MS_w}$$

Analogicznie jak to było dla statystyki t możemy porównać wartość F względem rozkładu F i wyznaczyć p-value.

Selekcja cech - f-value i p-value - zbiór Breast Cancer

Porównajmy wyniki analizy dla dwóch wybranych cech: „worst texture” (index 21) oraz „mean fractal dimension” (index 9). W wyniku przeprowadzonej analizy uzyskamy:

Wybrana cecha: worst texture

Relacja odchyłeń standardowych pomiędzy grupami: 0,989

f-value = 149,5969046860518 -> mamy tylko dwie klasy dlatego $t\text{-value} = \sqrt{f\text{-value}} = 12,231$

p-value = $1,078e-30$

Wybrana cecha: mean fractal dimension

Relacja odchyłeń standardowych pomiędzy grupami: 1,122

f-value = 0,09345929487492248 -> mamy tylko dwie klasy dlatego $t\text{-value} = \sqrt{f\text{-value}} = 0,306$

p-value = 0,76

Z porównania można wskazać, że cecha „mean fractal dimension” (index 9) nie różnicuje grup ze względu na klasę. Analogiczną analizę można przeprowadzić dla wszystkich cech i posortować wyniki, następnie wybrać cechy na podstawie progu (dla t-value, p-value) lub wybrać K cech.

Selekcja cech - test F - SciPy

W pakiecie SciPy dostępna jest funkcja:

```
f_value, p_value = f_classif(X, y)
```

która domyślnie używa jednoczynnikowej analizy wariancji do wyznaczania wartości testu.

Jeśli wartości naszych cech są nieujemne do selekcji cech można również użyć statystyki Chi-squared.

Omówione metryki wyznaczania wartości miar do różnicowania cech można wykorzystać poprzez zastosowanie klasy:

```
class sklearn.feature_selection.SelectKBest(score_func=<function f_classif>, *, k=10)
```

Wskazując jako score_func wybraną funkcję różnicowania cech.

Plan wykładu:

- Wprowadzenie
- Selekcja cech – metoda zysku informacji i podobne
- Selekcja cech – testy statystyczne
- **Podsumowanie**

Selekcja cech - wykorzystanie metryk

Pokazaliśmy szereg metryk umożliwiających określenie rankingu cech. Na podstawie rankingu możemy przeprowadzić procedurę selekcji cech stosując określoną strategię.

Przykładowo możemy wybrać K najlepszych cech stosując wybrany ranking.

W pakiecie SciPy jest np. klasa `SelectKBest`, która umożliwia podanie w konstruktorze metody wyznaczania rankingu cech, np.:

```
test = SelectKBest(score_func=chi2, k=5)
```

```
X_with_selected_features = test.fit_transform(X, y)
```


Oczywiście jako `score_func` możemy wykorzystywać różne funkcje (np. związane z testami statystycznymi, zyskiem informacji, itd.).

Selekcja cech - wizualizacja metryk

Ciekawą formą porównania relacji pomiędzy cechami jest wizualizacja wybranych metryk.

Przykładowo można to pokazać korelację pomiędzy cechami obliczając wartości współczynnika korelacji i pokazania wyników jako kolorowego obrazu, np.:


```
sns.heatmap(df_breast.corr(), cmap="YlGnBu");  
# sns.heatmap(df_breast.corr(),  
cmap="summer")
```



Selekcja cech - zastosowanie modeli

Wśród innych metod stosowanych selekcji cech należy również wskazać metody aposteriori, bazujące na zbudowanym modelu (np. klasyfikacji) i określeniu, które cechy nie wpływają na model, który została poddany walidacji.

Przykładowo, dla początkowego zbioru atrybutów $\{A1, A2, A3, A4, A5, A6\}$ oraz etykiet klasy $\{0, 1\}$ dla pewnego zbioru danych może się okazać, że uzyskamy drzewo decyzyjne jak poniżej.



Wniosek: atrybuty $\{A2, A3, A5\}$ nie są wykorzystywane. W przyszłości może należy je wyeliminować i na nowo zbudować model?

Selekcja cech - zastosowanie modeli

Analogicznie możemy wykorzystać szereg innych modeli. np. regresji logistycznej i eliminować cechy na podstawie wpływu cech reprezentowanego przez wartości współczynników regresji (wag).

Stosując wybrany model można wykorzystać różne strategie (metody) eliminacji cech. Szereg z tych strategii jest implementowanych we współczesnych pakietach oprogramowania.

Przykładowo:

Dla danego modelu: estimator

```
feature_selector = BorutaPy(estimator, n_estimators='auto', verbose=2, random_state=1)
```

```
feature_selector = RFE(estimator, 5)
```

```
feature_selector = SelectFromModel(estimator)
```

```
Feature_selector = SequentialFeatureSelector(estimator)
```

itd.

Przykłady praktyczne (notatnik interaktywny ML_04_02_Feature_Selection_Tests.ipynb)

Selekcja cech (testy) w środowisku Google Colaboratory/ Jupyter Notebook.

https://colab.research.google.com/drive/1t4EfpFOqQJr_3UWuDUI6GZsruuepYhxT?usp=sharing



POLITECHNIKA
GDAŃSKA

AI TECH



Dziękuję

Jacek Rumiński



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska

Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego

Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.