




POLITECHNIKA
GDAŃSKA



WYDZIAŁ ELEKTRONIKI,
TELEKOMUNIKACJI
I INFORMATYKI

Uczenie maszynowe

Wykład 2: Przygotowanie danych - przetwarzanie wstępne cz.1

Jacek Rumiński
Katedra Inżynierii Biomedycznej, Wydział ETI



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska



Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego

Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.

Plan wykładu:

- **Przetwarzanie wstępne - wprowadzenie**
- Oczyszczanie danych: Brakujące wartości
- Oczyszczanie danych: Wartości odstające
- Podsumowanie

Przetwarzanie wstępne

Zadaniem przetwarzania wstępnego jest między innymi przygotowanie poprawnych danych w celu:

- zapewnienia właściwego formatu (schematu) danych dla potrzeb analiz,
- zapewnienie reprezentatywnego (zbilansowanego) i odpowiednio złożonego zbioru danych (atrybuty i ich wartości),
- uzyskania wiarygodnych wyników w procesie zastosowania nauczonego modelu, nie obciążonego błędem danych,
- zapewnienie dużej wydajności procesu uczenia/analizy (jak najmniej danych pozwalających uzyskać wiarygodne wyniki, normalizacja danych),
- itd.

Przetwarzanie wstępne

Potrzeba wstępnego przetwarzania danych wynika także z faktu, że dane wejściowe są często:

- niekompletne: brakujące wartości atrybutów, brak istotnych dla analiz atrybutów, brak danych szczegółowych,
- posiadają błędy lub wartości nieoczekiwane (obserwacje/wartość odstępujące),
- niejednorodne: stosowane są różne reguły dla składowania tych samych atrybutów, stosowanie różnych miar (jednostek), różne ustawienia kalibracyjne w urządzeniach pomiarowych (np. w obrazowaniu medycznym), itd.

Przetwarzanie wstępne

Główne kategorie metod przetwarzania wstępnego:

- **pobranie i integracja danych** (ang. Data integration) , m.in.: integracja wielu baz danych, tabel, kolekcji, plików, kostek danych, itd.
- **oczyszczanie („czyszczenie”) danych danych** (ang. Data cleaning, data cleansing lub data scrubbing), m.in.: uzupełnienie wartości brakujących, usuwanie szumu i błędów danych, identyfikacja i eliminacja wartości odstających, usuwanie niejednorodności
- **przekształcanie (transformacja) danych** (ang. Data transformation), m.in.: normalizacja danych, agregacja (podgrupa: dyskretyzacja/kwantyzacja danych (ang. Data discretization), m.in.: kategoryzacja danych)
- **redukcja danych** (ang. Data reduction), m.in.: usuwanie redundancji, eliminacja danych nie wpływających na uzyskanie poprawnego wyniku, redukcja wielowymiarowości, selekcja cech

Plan wykładu:

- Przetwarzanie wstępne – wprowadzenie
- **Oczyszczanie danych: Brakujące wartości**
- Oczyszczanie danych: Wartości odstające
- Podsumowanie

Oczyszczanie danych - wartości nieokreślone (brakujące dane - ang. missing values)

Postępowanie

- Ignorowanie krotek, obiektów, wierszy, .., z atrybutami/polami o brakujących wartościach; operacja trudna gdy liczba takich elementów jest duża – utrata danych;
- Ręczne uzupełnienie danych (na podstawie innych źródeł danych) – nudne, pracochłonne, często wręcz nierealne;
- Automatyczne uzupełnienie atrybutów/pól pustych wartościami domyślnymi,
- Automatyczne uzupełnienie atrybutów/pól pustych wartościami średnimi dla danego sąsiedztwa, klasy, itp.;
- Automatyczne uzupełnienie atrybutów/pól pustych wartościami najbardziej prawdopodobnymi – zastosowanie reguły Bayesa lub drzew decyzyjnych.

Oczyszczanie danych - wartości nieokreślone (brakujące dane - ang. missing values)

Utworzenie schematu tabeli:

```
CREATE TABLE clinicalStudy (studyID INT PRIMARY KEY, birthdate DATE, sex BIT, bmi DECIMAL(6,4), heartProblem BIT);
```

Umożliwia sytuacje:

(1,null,null,null, null)

(2,null,1,24.6234, 1)

Czasami ustawiane są wartości domyślne (ale to chyba jeszcze gorzej):

(3, 1980-12-03, 0, 00.0000,0);

Wymuszanie wprowadzania danych (ale użytkownik może wpisać cokolwiek):

```
CREATE TABLE clinicalStudy (studyID INT PRIMARY KEY, birthdate DATE NOT NULL, sex BIT NOT NULL, bmi DECIMAL(6,4) NOT NULL, heartProblem BIT NOT NULL);
```


Oczyszczanie danych - wartości nieokreślone (brakujące dane - ang. **missing values**). Przykład - format ARFF i brakujące dane:

@relation clinicalStudy

@attribute studyID NUMERIC

@attribute age {30_40,41_50,51_60,61_65, 66_}

@attribute sex {0,1}

@attribute bmi NUMERIC

@attribute heartProblem {0,1}

@data

1,51_60,0,25.23,0

2,41_50,1,?,1



3,41_50,0,25.23,0

4,41_50,1,29.53,1

5,30_40,0,?,1



(...)

Oczyszczanie danych - wartości nieokreślone (brakujące dane - ang. missing values)

Missing values - przykłady

Wyszukaj wartości NULL (czasem oznaczone jako „?”), wartości domyślne (niezmienne):

Funkcje: ISNULL(X, 0), NVL(X, 0),

SELECT ISNULL(X); (MYSQL)

*SELECT * FROM tableName WHERE X IS NULL (SQLITE)*

Wyszukaj wartości atrybutu z innego zasobu (jeśli istnieje) - problem pseudoanonimowości:

SELECT birthdate FROM originalClinicalDataSet WHERE sex=1 AND bmi=24.6234 AND heartProblem=1;

Oczyszczanie danych - wartości nieokreślone (brakujące dane - ang. **missing values**). Przykład - WEKA i brakujące dane:

@relation clinicalStudy

@attribute studyID NUMERIC

@attribute age {30_40,41_50,51_60,61_65, 66_}

@attribute sex {0,1}

@attribute bmi NUMERIC

@attribute heartProblem {0,1}

@data

1,51_60,0,25.23,0

2,41_50,1,**27.4175**,1


3,41_50,0,25.23,0

4,41_50,1,29.53,1

5,30_40,0, **27.4175**,1

(...)

Wartości średnie



Przykłady praktyczne (notatnik interaktywny ML_02_Data_Missing_Values)

Oczyszczanie danych - wartości nieokreślone w środowisku Google Colaboratory/ Jupyter Notebook.

https://colab.research.google.com/drive/1RvOv8v81_PuH0l0ELpvcqkWSjZbilqeS?usp=sharing

Plan wykładu:

- Przetwarzanie wstępne – wprowadzenie
- Oczyszczanie danych: Brakujące wartości
- **Oczyszczanie danych: Wartości odstające**
- Podsumowanie


Oczyszczanie danych - wartości odstające (ang. outliers)

Wartości (obserwacje) odstające – to takie wartości dane cechy, lub takie próbki, które odstają od innych wskazując, że ich źródłem może być błąd (ludzki, maszyny, metody, itp.) lub same w sobie stanowią nieznaną wcześniej prawidłowość (przypadek).

Wartość odstająca może wynikać również z faktu, że mamy mało liczebną próbkę i tak się akurat złożyło, że z populacji wylosowaliśmy $k-1$ bardzo podobnych próbek i 1 zupełnie inny (ale podobny do pozostałych, niepomierzonych próbek populacji danego rodzaju). Jest to wówczas wartość odstająca w naszej próbce (ale nie w populacji).

PRZYKŁADY

Wzrost = {167, 154, 178, 163, **280**, 191, 182, 179 }



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane jednowymiarowe

Metody nieparametryczne:

1. Wyznacz kwartyle (wartości ćwiartkowe) Q1 i Q3, a następnie oblicz rozstęp międzykwartylowy (ang. interquartile range, IQR): $IQR = Q3 - Q1$


IQR pokrywa obszar 50% masy prawdopodobieństwa w próbie (co zilustrowano dla standardowego rozkładu normalnego).

Wyznaczamy limity:

$$\text{limit_dolny} = (x_ref_1 - 1.5 \times IQR)$$

$$\text{limit_górny} = (x_ref_2 + 1.5 \times IQR)$$

gdzie: x_ref_1/x_ref_2 to wartości referencyjna:
mean, median, Q1, Q3



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane jednowymiarowe

Metody nieparametryczne:

2. Wyznacz wartość średnią (lub medianę) i odchylenie standardowe. Następnie ustaw limity.


Wyznaczamy limity (np. $k=1,2,3$, itp.):

$$\text{limit_dolny} = (x_{\text{ref}} - k \times \text{std_dev})$$

$$\text{limit_górnny} = (x_{\text{ref}} + k \times \text{std_dev})$$

gdzie: x_{ref} to wartość referencyjna: mean, median, itd..

Dla rozkładu normalnego zakres między wartościami odchyłeń standardowych pokrywa obszar ok. 68%.



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane jednowymiarowe

Metody nieparametryczne:

3. Wykorzystaj inne podobne kryteria:

a) Metoda heurystyczna związana ze statystyka Z (Z-score):

$$z_i = (x_i - \text{mean}(x)) / \text{std_dev}(x)$$

(stosować dla większej liczby próbek).

Kryterium: jeśli wartość statystyki $|z|$ jest większa od limitu (np. 3) wówczas wykryty wartość odstającą.

b) Podobnie dla modyfikacji Z-Score

$$z_i = 0,6745(x_i - \text{mean}(x)) / \text{MAD}$$
$$\text{MAD} = \text{median}(x_i - \text{median}[x])$$

c) Lub inne zastosowanie innych odchyłeń: np. χ^2

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane jednowymiarowe

Metody parametryczne:

Można również wykorzystać szereg metod parametrycznych bazujących na testach:

- Grubbs'a (czy maks./min. jest outlierem)
- Rosnera
- Dixona (z szeregiem odmian)
- i inne.

Zwykle stawiamy hipotezę zerową (H_0), że w próbie brak jest obserwacji odstających i przeprowadzamy test.

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe

Klastry (analiza zgrupowań)

Założmy prosty cel działań: Klasyfikacja kurczaków na te, które będą kurami i te, które będą kogutami. Jak to zrobić? Założmy, że nie wiemy i poszukujemy metody na bazie obserwacji własności kurczaków (podział na grupy – metody nienadzorowana).


Zaproponujemy dwie własności (cechy): wagę kurczaka i wzrost kurczaka (oczywiście w określonym wieku kurczaka).

Założmy, że mamy 17 kurczaków. Każdego zmierzymy i zważymy uzyskując dla każdego wektor pomiarowy: $\{W_i, H_i\}$, gdzie i – indeks kurczaka.

Możemy teraz wykreślić wartości wektory pomiarowe (jako punkty) w przestrzeni cech (dwuwymiarowej – waga i wzrost):


Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe



Oczyszczanie danych - wartości odstające (ang. outliers)


Metody detekcji wartości odstających - dane dwuwymiarowe



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe

Założmy teraz, że uzyskano pomiary dla 18 kurczaka:



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe

NOWY WEKTOR DANYCH NIE PASUJE DO INNYCH – OBSERWACJA ODSTAJĄCA

WZROST
KURCZAKA

Wartość średnia
wektora
pomiarowego w
danej grupie


μ_1

K2

μ_2

K1

WAGA KURCZAKA



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe

Jakie kryterium przyjąć w celu decyzji dotyczącej o tym, że dany wektor pomiarowy jest obserwacją odstającą?

Najprościej zastosować miarę odległości wektora od wartości średnich klastrów. Na przykład miarę odległości Euklidesową

$$d(p, q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2}$$

Miarę odległości miejską (ang. City Block distance lub Manhattan distance - poruszamy się ulicami według „bloków”):

$$d(p, q) = |p_1 - q_1| + |p_2 - q_2|$$

Analogicznie dla k wymiarów (suma po k).

Kryterium? Jeśli odległość od każdego klastra większa niż zadany limit - OUTLIER!

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe



Jeśli nie mamy wcześniejszego modelu to możemy testować próbki, czy są obserwacjami odstępującymi np. poprzez:

- zastosowanie prezentowanych wcześniej reguł dla danych jednowymiarowych - każda cech oddzielnie,
- badanie sąsiedztwa danej próbki, poszukują takich próbek, które są najbardziej oddalone od pozostałych,
- inne metody.

W metodzie bazujące na analizie sąsiedztwa poszukujemy zwykle **k-najbliższych sąsiadów** (ang. ***k nearest neighbours - kNN***). Jeśli $k=1$, poszukujemy najbliższego sąsiada (stosując daną miarę odległości). Jeśli $k=2$, poszukujemy dwóch najbliższych sąsiadów (a każdemu przypisujemy ranking - pierwszy, drugi sąsiad, itp.).


Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe



Upraszczając, weźmy $k=1$.


- Obliczamy odległości pomiędzy próbką i , a pozostałymi
- Wybieramy najmniejszą odległość - znaleźliśmy najbliższego sąsiada dla próbki i (zapisujemy indeks oraz odległość)
- Analogicznie dla pozostałych próbek
- Analizujemy, czy jest jakaś próbka, dla której odległość do najbliższego sąsiada jest większa niż przyjmowany próg (który może dotyczyć również rozkładu tych odległości).

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe


Problemy:

Dwie próbki odstające blisko siebie



1NN nie wystarczy, może 2NN?

Różna gęstość klastrów




Proste kNN nie wystarczy - trzeba badać sąsiedztwo dla sąsiadów

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe

Problem gęstości klastrów - co jeśli jeden klaster zawiera skupione próbki, a inny rozproszone



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe

Metoda Local Outlier Factor (<https://doi.org/10.1145%2F335191.335388>)

Próbki, które mają znacząco mniejszą gęstość (sąsiadów) to próbki odstające.

1. Niech x_k to k -ty, najbliższy sąsiad próbki x , k najbliższych sąsiadów x to $N_k(x)$
2. K-odległość od x to:

$$d_k(x) = d_k(x, x_k)$$

3. Zasięg to odległość próbki x od próbki y określana jako:

$$\text{reachability-distance}_k(x, y) = \max\{d_k(y), d(x, y)\}$$

4. Lokalna gęstość zasięgu (dostępności punktu x) to:

$$\text{lrd}_k(x) = |N_k(x)| / (\sum_{y \in N_k(x)} \text{reachability-distance}_k(x, y))$$


5. LOF dla próbki x wyznaczamy jako relacja gęstości sąsiadów (y) do gęstości danej próbki (x) (lokalna gęstość próbki odstającej < lok. gęstości próbek sąsiedztwa $\rightarrow$ duże LOF $\rightarrow$ outlier):

$$\text{LOF}_k(x) = \sum_{y \in N_k(x)} \text{lrd}_k(y) / \text{lrd}_k(x) / |N_k(x)|$$

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe: **LOF**

Rozpatrzmy zestaw próbek {a,b,c,d,e,o} zilustrowany obok. Odległości pomiędzy punktami:



a b 5,830951894845301

a c 5,0

a d 1,0

a e 1,4142135623730951

a o 7,615773105863909

b c 1,0

b d 5,0

b e 4,47213595499958

b o 6,324555320336759

c d 4,242640687119285

c e 3,605551275463989

c o 6,708203932499369

d e 1,0

d o 6,708203932499369

e o 7,211102550927978

(rozkład wartości inspirowany :

<https://www.youtube.com/watch?v=CePgbdVdLvg>)

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe: **LOF**

W naszym przykładzie przyjmujemy $k=2$ (hiperparametr) w celu pokazania w jaki sposób dokonuje się obliczeń dla LOF. Znajdźmy najbliższych sąsiadów dla o, b, c, d (według powyższych obliczeń):

o b sąsiad: 1, $d(o,b)=6,324555320336759$

o c sąsiad: 2, $d(o,c)=6,708203932499369$

b c sąsiad: 1,


b e sąsiad: 2,

c b sąsiad: 1,

c e sąsiad: 2,

d a sąsiad: 1,

d e sąsiad: 2,



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe: **LOF**


Policzmy zasięg dla naszych wybranych punktów:

$$\text{reachability-distance}_2(o,b) = \max(d_2(b), d(o,b))$$

1. $d(o,b)=6,324555320336759$
2. 2-sąsiad dla b to e, $d(b,e)=4,47213595499958$
3. $RD_2(o,b) = \max(d(b,e), d(o,b))$
 $\max(4,47213595499958, 6,324555320336759)$

$$\text{reachability-distance}_2(o,c) = \max(d_2(c), d(o,c))$$

1. $d(o,c)=6,708203932499369$
2. 2- sąsiad dla c to e, $d(c,e)=3,60555127546398$
3. $RD_2(o,c) = \max(d(c,e), d(o,c))$
 $\max(3,60555127546398, 6,708203932499369)$



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe: **LOF**

Policzmy wartości lokalnej gęstości zasięgu (dostępności punktów) LRD dla wybranych punktów:

Dla $k=2$:

$$\begin{aligned} \text{lrld}(o,2) &= 2/(\text{RD}_2(o,b) + \text{RD}_2(o,c)) = \\ &= 2/(6.324555320336759 + 6.708203932499369) = 0.15345944486504415 \end{aligned}$$


Analogicznie dla $\text{lrld}(b,2) = \dots$ i $\text{lrld}(c,2) = \dots$

$$\text{LOF}(o,2) = (0.5 * (\text{lrld}(b,2) + \text{lrld}(c,2))) / \text{lrld}(o,2)$$

Outlier:

Jeśli np. $\text{LOF} < T$ (małe LOF) to inlier inaczej outlier (czyli duże LOF - to outlier)


{W sklearn wartości są mnożone przez -1, stąd mniejsze wartości [większe bezwzględnie] to wartości odstające}



Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających - dane dwuwymiarowe

Modele mogą być różne, na przykład modele regresyjne. Wówczas podobnie możemy sprawdzać (metodami jak wyżej, lub innymi) czy dany punkt jest obserwacją odstającą. W zadaniach regresji rozróżnia się czasami obserwacje niestandardowe jako: odstające (powodujące duży błąd dopasowania), wpływowe (silny wpływ na a i b , ekstremalne), itp.



Przykłady praktyczne (notatnik interaktywny ML_02_02_Data_Outliers)

Oczyszczanie danych - wartości odstające w środowisku Google Colaboratory/ Jupyter Notebook.

https://colab.research.google.com/drive/1dueKvmP3pWd5O7_OQlsPcCgLEtPyTsvw?usp=sharing

Oczyszczanie danych - wartości odstające (ang. outliers)

Metody detekcji wartości odstających

W analizie wartości odstających używa się jeszcze szereg innych metod bazujących np. na :

- DBSCAN (Density Based Spatial Clustering of Applications with Noise, <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html?highlight=dbscan>)
- OPTICS (Ordering Points To Identify the Clustering Structure ,<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.OPTICS.html?highlight=optics>)
- Drzewach decyzyjnych (np. Isolation Forest: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html>)
- Angle Based Outlier Detection
(<https://www.dbs.ifi.lmu.de/~zimek/publications/KDD2008/KDD08-ABOD.pdf>)
- itp.

Plan wykładu:

- Przetwarzanie wstępne – wprowadzenie
- Oczyszczanie danych: Brakujące wartości
- Oczyszczanie danych: Wartości odstające
- **Podsumowanie**

Oczyszczanie danych

Przypadki szczególne w zakresie oczyszczania (redukcji) danych:

- Usuwamy niezmiennie dane (zmiana wartości jedynie w zakresie błędu),
- Badamy sensowność danych, np. data urodzenia wcześniejsza niż inne daty dotyczące pacjenta, PESEL a data urodzenia, itd.
- Badamy interwały pomiędzy datami (np. daty wizyt/badania pacjenta)
- Analizujemy wartości liczbowe – oczekiwane dziedziny i przedziały, oczekiwane zależności (np. waga/wzrost/wiek/płeć).
- Analizujemy poprawność danych kodowanych, zakresy wartości laboratoryjnych, itd.

Wszystkie opisywane zabiegi zaliczane do metod oczyszczania danych tworzą część procesu kontroli i zapewniania jakości danych.



POLITECHNIKA
GDAŃSKA



WYDZIAŁ ELEKTRONIKI,
TELEKOMUNIKACJI
I INFORMATYKI

Dziękuję

Jacek Rumiński



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska



Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego

Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.