




POLITECHNIKA
GDAŃSKA



WYDZIAŁ ELEKTRONIKI,
TELEKOMUNIKACJI
I INFORMATYKI

Uczenie maszynowe

Wykład 3: Przygotowanie danych - przetwarzanie wstępne cz. 2

Jacek Rumiński
Katedra Inżynierii Biomedycznej, Wydział ETI



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska



Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego
Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.

Plan wykładu:

- **Przekształcanie danych**
- Normalizacja danych
- Redukcja danych
- Podsumowanie

Przekształcanie danych

Przekształcanie (transformacja) danych to część przetwarzania wstępnego mająca na celu m.in.:

- **zmianę reprezentacji danych** (np. przekształcanie danych nominalnych na liczbowe, wektorowe, tworzenie nowych zmiennych, kategoryzację danych, itp.)
- **normalizację danych** (np. zmianę zakresu wartości)
- **redukcję danych** (usuwanie redundancji, eliminacja danych nie wpływających na uzyskanie poprawnego wyniku, redukcja wielowymiarowości, selekcja cech)

Przekształcanie danych - zmiana reprezentacji danych

Zmiana reprezentacji danych dotyczy często przypadków:

- Konwersję danych nominalnych (kategorii) do postaci liczbowej lub zbioru liczb (np. zamianę wartości nominalnej na liczbę według przyjętego słownika, np. choroba = {„tak”, „nie”} -> {1, 0})
- Konwersję danych liczbowych do postaci zbioru kategorii (np. podział danych na przedziały i przypisanie etykiety, np. wiek 0-10 -> „dziecko”)
- Zmianę reprezentacji liczby (np. zmianę liczb rzeczywistych, zmiennoprzecinkowych do całkowitych - wiek 12,3456 -> 12)
- Zmianę reprezentacji kategorii (np. zmniejszanie liczby kategorii: {„zdrowy”, „chory na A”, „chory na B”} -> {„zdrowy”, „chory”}, tworzenie hierarchii kategorii: kraj->województwa -> powiaty->gminy)
- Tworzenie nowych atrybutów (np. waga, wzrost -> bmi; paczki wypalonych papierosów i lata palenia -> paczkołata)

Przekształcanie danych - zmiana reprezentacji danych

Przykład metody: OneHotEncoding

W metodzie tej dla zakodowania danych atrybutu typu nominalnego budujemy wektor o rozmiarze równym licznie wszystkich, różnych wartości tego atrybutu. Indeks pozycji wektora odnosimy do wartości typu nominalnego. Każda pozycja wektora ma wartość 0, z wyłączeniem tej pod indeksem wskazującym określoną wartość typu nominalnego. W tej wybranej pozycji będzie 1.

Na przykład:

(id, zwierzątko, wiek)

(1, "kot", 8)

(2, "pies", 11)

(3, "kot", 6)

Liczba różnych wartości nominalnych atrybutu 2 (czyli „zwierzątko”) to: "kot" lub "pies".

Przekształcanie danych - zmiana reprezentacji danych

Przykład metody: OneHotEncoding

Zatem zakładając $w = [\text{indeks0} \rightarrow \text{"kot"}, \text{indeks1} \rightarrow \text{"pies"}]$, kodujemy etykiety poprzez ich indeksy jako

(id, zwierzątko, wiek)

(1, [1,0], 8)

(2, [0,1], 11)

(3, [1,0], 6)

lub

(id, czy_kot, czy_pies, wiek)

(1, 1,0, 8)

(2, 0,1, 11)

(3, 1,0, 6)

Przekształcanie danych - zmiana reprezentacji danych

Przykład metody: OneHotEncoding

W przypadku danych multimedialnych też przypisywane są etykiety dla problemu klasyfikacji tych danych.

Przykładowo w bazie MNIST znajduje się kilkadziesiąt tysięcy zeskanowanych obrazków ręcznie zapisanych cyfr. Każdemu obrazkowi przypisano etykietę:

(„zero”, „jeden”, ..., „dziewięć”) <- to jest nasz słownik

(0, 1, 2, 3, 4, 5, 6, 7, 8, 9) <- lub to jest nasz słownik

Dla celów klasyfikacji (np. z użyciem sieci neuronowych) stosuje się często reprezentację OneHotEncoding tych etykiet.

„siedem” -> 7 -> **$v = [0,0,0,0,0,0,0,1,0,0]$**



v	0	0	0	0	0	0	0	1	0	0
idx	0	1	2	3	4	5	6	7	8	9

Obraz utworzony na podstawie zbioru danych MNIST:
<http://yann.lecun.com/exdb/mnist>

Przekształcanie danych - zmiana reprezentacji danych

Przykład metody: OneHotEncoding

Przykładowo:

```
from tensorflow.examples.tutorials.mnist import input_data
mnist = input_data.read_data_sets("/tmp/data/", one_hot=False)
```

Wynik klasyfikacji może być również zakodowany w ten sposób i dlatego w celu uzyskania prostej etykiety klasy można zastosować operację:

1. znajdź wartość maksymalną w wektorze v
2. pobierz indeks dla tej wartości maksymalnej

Realizacja, np. funkcje typu **argmax**:

```
# decode 1-hot encoded data to simple class labels
```

```
true_label = tf.argmax(mnist.test.labels, 1)
```

```
predicted_label = tf.argmax(dets, 1)
```



v	0	0	0	0	0	0	0	1	0	0
idx	0	1	2	3	4	5	6	7	8	9

Obraz utworzony na podstawie zbioru danych MNIST:
<http://yann.lecun.com/exdb/mnist>

Przekształcanie danych - zmiana reprezentacji danych

Embedding - osadzanie typów nominalnych za pomocą danych numerycznych (najczęściej w formie tensorów: wektorów lub macierzy).

Rozpatrzmy potrzebę kodowania słów. Oczywiście słowo to zbiór znaków, które łatwo zamienić na ciąg liczb, tylko liczby te nie oddają znaczenia słowa.

Chcemy jednak zakodować to słowo tak, aby w przyszłości można było taki kod wykorzystać w zadaniach związanych np. z interpretacją (czy rozumieniem) tekstu. Naszym celem będzie odpowiednie osadzenie (ang. embedding) zmiennej nominalnej do reprezentacji numerycznej (np. jako wektor liczb).

Słowo będzie typowo reprezentowane jako zmienna nominalna, np. "koń".

Przykładowo, słowo "koń" może być częścią słownika (zbioru wszystkich wyrazów języka). Załóżmy, że nasz słownik jest bardzo ubogi:

$V = ['koń', 'pies', 'ma', 'cztery', 'dwie', 'łapy', 'nogi']$

Przekształcanie danych - zmiana reprezentacji danych

Embedding - osadzanie typów nominalnych za pomocą danych numerycznych (najczęściej w formie tensorów: wektorów lub macierzy).

$V = ['koń', 'pies', 'ma', 'cztery', 'dwie', 'łapy', 'nogi']$

Rozmiar słownika to $|V|=7$. Każde słowo reprezentować możemy (OneHotEncoding) wektorem o długości 7, np. dla słowa "koń":

$w = [1, 0, 0, 0, 0, 0, 0]$

a dla słowa "cztery":

$w = [0, 0, 0, 1, 0, 0, 0]$

Kodujemy zatem podobieństwo względem słownika.

Biorąc pod uwagę realne rozmiary słownika danego języka (miliony, a może więcej pozycji) uzyskalibyśmy bardzo rzadką reprezentację danych (dużo 0).

Przekształcanie danych - zmiana reprezentacji danych

Embedding - osadzanie typów nominalnych za pomocą danych numerycznych (najczęściej w formie tensorów: wektorów lub macierzy).

Dlatego często stosuje się inne kodowanie (osadzanie), np. kodując słowo zestawem wartości liczbowych reprezentujących podobieństwo do pewnych ogólnych kategorii (np. "koń": zwierzę > 1.0 , czasownik > -1.0 , itd.).

Wówczas uzyskujemy również wektor liczb dla pojedynczego słowa, w ramach którego zakodowano znaczenie słowa w odniesieniu do np. szeregu kategorii/funkcji rzeczy.

Przykładowo, zakładając 6 cech uzyskamy:

$w = [1.0, -1.0, 0.234, 0.9, 0.0001, -1.0]$

Taki wektor można porównywać z innymi, można nawet przeprowadzać operacje redukcji danych, itp.

Szereg innych sposobów konwersji dla potrzeb przetwarzania języka naturalnego zostanie przedstawione na innych przedmiotach kursu poświęconego sztucznej inteligencji.

Przekształcanie danych - zmiana reprezentacji danych

Konwersję danych realizujemy najczęściej za pośrednictwem języków programowania, które umożliwiają zdefiniowanie przekształcenia poprzez zapis funkcji czy metod (obiektu).


Doświadczenia wcześniejsze pozwoliły naukowcom i inżynierom opracować szereg pakietów oprogramowania, które można bezpośrednio wykorzystać w językach takich jak Python, R, Java, itp.

Przykładowo w środowisku Python dostępny jest pakiet *scipy-learn* dostarczający szereg klas implementujących operacje zmiany reprezentacji danych, szczególnie w ramach podpakietu: *sklearn.preprocessing*. Znajdziemy tam m.in. klasy : *OrdinalEncoder*, *LabelEncoder*, *OneHotEncoder*, *StandardScaler*, itd.

Istnieją również gotowe produkty, które określoną funkcjonalność dostarczają poprzez komponenty interfejsu graficznego. Wśród nich można wymienić programy Weka, KNIME, RapidMiner, itd. Na kolejnych slajdach przedstawiono przykłady przekształcania danych w środowisku Weka.


Przekształcanie danych - zmiana reprezentacji danych

Zastosowanie wyrażeń matematycznych w obliczaniu nowych atrybutów na podstawie przekształcenia jednego atrybutu, np. obliczanie wieku (bieżący rok - rok urodzenia reprezentowany przez zmienną A)



Przekształcanie danych - zmiana reprezentacji danych

Zastosowanie wyrażeń matematycznych w obliczaniu nowych atrybutów na podstawie przekształcenia wielu atrybutów, np. obliczanie bmi (kolejne zmienne są numerowane jako $a_1 \dots a_N$)



Przykłady praktyczne (notatnik interaktywny ML_03_01_Data_Transformation)

Przekształcanie danych w środowisku Google Colaboratory/ Jupyter Notebook.

<https://colab.research.google.com/drive/1WH1CVFKe-QXuGzRMaeutkv70Vbm5b1mz?usp=sharing>

Plan wykładu:

- Przekształcanie danych
- **Normalizacja danych**
- Redukcja danych
- Podsumowanie

Normalizacja danych

Rozpatrzmy przykład zbioru danych parametrów obrazów opisujących podejrzaną zmianę w detekcji nowotworów piersi (`sklearn.datasets import load_breast_cancer`). Dla tego zbioru wybierzmy dwie cechy: średnie pole powierzchni zmiany i średnia asymetria.

	mean area	mean symmetry
count	569.000000	569.000000
mean	654.889104	0.181162
std	351.914129	0.027414
min	143.500000	0.106000
25%	420.300000	0.161900
50%	551.100000	0.179200
75%	782.700000	0.195700
max	2501.000000	0.304000

Normalizacja danych

Zróbmy prosty eksperyment dla dwóch wymyślonych próbek:

("mean area ", " mean symmetry ")

(1000; 0,2)

(1001; 0,3)

Spróbujmy teraz porównać ich podobieństwo za pomocą miary odległości według metryki Euklidesa:

$$d = \sqrt{(1001-1000)^2 + (0,3-0,2)^2} = \sqrt{1+0,01} = 1,00498$$

Łatwo zauważyć, że o różnicy decyduje głównie zmiana wartości atrybutu "mean area".

Normalizacja danych

Warto ponadto zauważyć, że zmiana wartości atrybutu "mean area" była na poziomie mniejszym niż 0,05% ($1/(2501-143,5)$), podczas gdy zmiana wartości atrybutu "mean symmetry" była na poziomie większym niż 50% ($0,1/(0,304-0,106)$).

W rezultacie niewielka zmiana pierwszego z parametrów odegrała znacznie większą rolę przy porównywaniu próbek, niż bardzo duża zmiana drugiego z parametrów.

Między innymi z tych względów warto przeprowadzić normalizację danych.

Typowe normalizacje:

- skalowanie do zakresu (np. do $[0, 1]$ lub $[-1, 1]$),
- dzielenie przez stałą,
- normalizacje z wykorzystaniem funkcji wykładniczych,
- normalizacja min-max,
- standaryzacja (z-score).

Normalizacja danych

1. **Skalowanie liniowe**, $y=f(x)=ax+b$, np. w zamianie zakresu wartości wag koloru $[0, 255]$ do zakresu $[-1,1]$ lub $[0, 1]$,
2. **Dzielenie przez stałą** jest oczywiście specjalnym przypadkiem skalowania liniowego, np. stosowane przy zmianie jednostek danych (np. mile na kilometry, itp.).
3. **Normalizacja z wykorzystaniem funkcji wykładniczej** to najczęściej przekształcenia zakresu wartości, np. (skalowanie do $[0,1]$):

$$x' = \frac{e^x}{1-e^x} = \frac{1}{1-e^{-x}}$$

4. **Skalowanie min-max** to przekształcenie eliminujące offset w danych i normalizujące do zakresu wartości:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Normalizacja danych

4b. Skalowanie min-max do nowego przedziału wartości min' i max':

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} (x'_{max} - x'_{min}) + x'_{min}$$

5. **Normalizację z-score (standaryzacja)** przekształca dane w celu uzyskania wartości średniej równej 0 oraz odchylenia standardowego równego 1, czyli jak dla standardowego rozkładu normalnego, stąd metoda ta nazywana jest również standaryzacją:

$$x' = \frac{x - \bar{x}}{s}$$

gdzie: $\bar{x}$ - wartość średnia dla zbioru próbek (w odróżnieniu od wartości średniej populacji),
s - odchylenie standardowe dla zbioru próbek.

Normalizacja danych

Dla naszego wcześniejszego przykładu:

("mean area", "mean symmetry")

(1000; 0,2)

(1001; 0,3)

po standaryzacji otrzymamy:

("mean area", "mean symmetry")

(0,9806679178009738, 0,6871650893083427)

(0,983509520104142, 4,334898866248587)

Widać teraz, że przykładowa zmiana wartości pierwszej z cech będzie mniej znacząca (i słusznie, bo względem zakresu ta zmiana wynosiła mniej niż 0,05%) niż zmiana drugiej z cech (tu zmiana względem zakresu była ponad 50%).

Normalizacja danych

Zamiast stosować własne implementacje metod normalizacji można zastosować szereg klas/funkcji dostępnych w pakietach Pythona, np. *scipy-learn* (*MinMaxScaler*, *MaxAbsScaler*, *RobustScaler*, *StandardScaler*, itd.).

W kolejnych przykładach będziemy stosować np. *StandardScaler* (standaryzacja) i inne metody normalizacji.

Przekształcenia danych mogą mieć wpływ na dalsze etapy procesu analizy danych: mogą przyspieszać obliczenia (lub w ogóle umożliwiać uzyskanie zbieżności w procesie poszukiwania rozwiązania). Jest to szczególnie ważne przy dużej liczbie parametrów (np. uczenie głębokie).

mogą zmieniać model prowadząc do innego wyjaśniania wpływu danych (np. po logarytmowaniu zmiennych niezależnych).

Należy również pamiętać, że zmienne (obserwacje, przesłanki) mogą zależeć od siebie lub ich kombinacja (relacja) może mieć wpływ na wynik klasyfikacji/predykcji. Mówimy wówczas o efekcie interakcji pomiędzy zmiennymi/cechami (features interactions) lub o zależności w danych.

Przykłady praktyczne (notatnik interaktywny ML_03_02_Data_Normalization)

Normalizacja danych w środowisku Google Colaboratory/ Jupyter Notebook.

<https://colab.research.google.com/drive/1koFpmrZXTcXMoar8ytgSKchR1bAqrSfY?usp=sharing>

Plan wykładu:

- Przekształcanie danych
- Normalizacja danych
- **Redukcja danych**
- Podsumowanie

Redukcja danych

Jedynym z celów etapu redukcji danych jest generacja mniejszego zbioru danych niż oryginalny dającego te same lub bardzo podobne (tj. z akceptowalnym błędem) parametry jakości budowanego modelu.

Często również redukcja danych jest konieczna, jeśli danych jest zbyt dużo i ze względu na specyfikę algorytmu czy sprzętu (np. pamięć RAM) nie możemy wykorzystać pełnego zbioru danych.

Inną sytuacją potrzeby wykorzystania redukcji danych jest zbyt zróżnicowany zbiór danych i uzyskane modelu są zbyt skomplikowane na przykład w odniesieniu do interpretacji (wyjaśniania modeli – np. drzewo decyzyjne z tysiącami gałęzi czy węzłów).

Redukcja danych

Jeśli dana cecha nie prowadzi do zróżnicowania danych (np. wszystkie wartości takie same) wówczas można ją usunąć i nie wpływa to na jakość budowanego modelu.

Jak ilościowo zbadać, czy określona cecha różnicuje dane?

Można wyznaczyć parametry statystyczne (wariancja = 0 -> brak zróżnicowania danych).

Inną często stosowaną miarą jest entropia.

Redukcja danych

Entropia – miara zróżnicowania danych.

Założmy, że mamy przykładowo 4 symbole A, C, T, G oraz sekwencję 16 znaków złożonych z tych symboli. Ile bitów zapiszemy, lub prześlemy przez łącze (sieć) w celu reprezentacji takiej sekwencji?

Pytanie można też postawić inaczej: Ile, średnio, potrzebujemy bitów na znak?

Założmy prosty model wykorzystujący 2 bity na znaków, np.:

A - 00

C - 01

T - 10

G - 11

Redukcja danych

Entropia – miara zróżnicowania danych.

Wówczas sekwencja 16 znaków może wyglądać tak:

ACTGGTCAACTGGTCA

00101011111001000010101111100100

Mamy $2 \cdot 16$ bitów = 32 bity, średnio $32/16$ znaków = 2 bity/znak

Zwróćmy jednak uwagę, że w powyższej sekwencji każdy symbol występuje tyle samo razy.

Prawdopodobieństwo wystąpienia każdego znaku jest zatem jednakowe:

$$P(\text{znak}) = P(A) = P(C) = P(T) = P(G) = 0,25$$

$$\{ P(A) = \text{ile razy występuje A} / \text{liczba znaków} = 4/16 = 1/4 = 0,25 \}$$

Redukcja danych

Entropia – miara zróżnicowania danych.

Rozważmy przypadek różnych prawdopodobieństw, np.:

$P(A)=0,5$; $P(C)=0,125$; $P(T)=0,25$; $P(G)=0,125$

Przykładowo: **AATAGTCAACTAGTAA**

Oczywiście znów możemy zastosować kodowanie (metodę reprezentacji) wykorzystujące 2 bity na znak.

Ale, załóżmy, że zastosujemy inne kodowanie (z pewnym uproszczeniem):

A -> 1	(1 bit)
T -> 01	(2 bity)
C -> 001	(3 bity)
G -> 000	(3 bity)

Redukcja danych

Entropia – miara zróżnicowania danych.

Ile wówczas użyjemy bitów w naszych przykładzie:

AATAGTCAACTAGTAA

8*A -> 8 bitów

4*T -> 8 bitów

2*C -> 6 bitów

2*G -> 6 bitów

Zatem raz otrzymamy 28 bitów, czyli średnio $28/16 = 1,75$ bita na symbol!

W naszym przykładzie mieliśmy bardzo mało symboli i krótką sekwencję znaków. Co w przypadku bardzo długiej sekwencji. Czy możemy określić jaka jest teoretycznie średnia liczba bitów/znak?

Redukcja danych

Entropia – miara zróżnicowania danych.

W tym celu możemy zastosować miarę entropii, definiowaną jako:

$$H = - \sum_{k=0}^{K-1} p(k) \cdot \log_2(p(k))$$

gdzie:

K – liczba symboli

k – zmienna przyjmująca wartości kolejnych symboli

$p(g)$ – prawdopodobieństwo wystąpienia symbolu.

Dla naszego przykładu:

$$\begin{aligned} H &= - \sum_{k=0}^3 p(k) \cdot \log_2(p(k)) \\ &= -0,5 \cdot \log_2(0,5) - 0,25 \cdot \log_2(0,25) - 0,125 \cdot \log_2(0,125) - 0,125 \cdot \log_2(0,125) \end{aligned}$$

$$H = (-0,5 \cdot -1) + (-0,25 \cdot -2,0) + (-0,125 \cdot -3,0) + (-0,125 \cdot -3,0) = 0,5 + 0,5 + 0,375 + 0,375 = \mathbf{1,75!}$$

Redukcja danych

Entropia – miara zróżnicowania danych.

Obliczana wartość entropii (optymalne kodowanie) okazała się identyczna jak wartość wyznaczona na podstawie przypisania kodów do poszczególnych symboli.

Kiedy wartość entropii równa jest np. 1?

Wówczas, gdy mamy rozkład równomierny (wszystkie wartości prawdopodobieństw są równe $P(n)=1/K$, gdzie K – liczba symboli, np. :

dla $K=2$:

$$H=(-0,5 \cdot -1)+(-0,5 \cdot -1,0)=\mathbf{1,00!}$$

dla $K=4$:

$$H=(-0,25 \cdot -2,0)+(-0,25 \cdot -2,0)+(-0,25 \cdot -2,0)+(-0,25 \cdot -2,0) = 2,00, \text{ itd.}$$

Kiedy wartość entropii równa jest 0? Wówczas, gdy prawdopodobieństwo znaku jest równe 1, np. dla $K=2$: $H=(-1 \cdot 0)=0$

Redukcja danych

Entropia – wykorzystanie do dyskretyzacji danych.

Jak dokonać dyskretyzacji zmiennej w sposób automatyczny? Wykorzystajmy do tego miarę entropii.

Mając zbiór D zestawu próbek dla zmiennej V poszukujemy takiego progu T , który pozwoli nam optymalnie podzielić zbiór D tak, aby uzyskać dwa podzbiory $D1$ i $D2$. W tym celu zbadajmy wszystkie możliwe (potencjalne) wartości parametru T (T_i):

$$H(D, T_i) = \frac{L(D1)}{L(D)} H(D1) + \frac{L(D2)}{L(D)} H(D2)$$

gdzie: $H(.)$ – entropia, $L(a)$ – liczba elementów a ;

T_i , dla którego $H(D, T)$ jest minimalne (najmniejsze rozproszenie w obrębie każdej grupy) jest wybierane jako optymalny próg podziału (binaryzacji):

$$\operatorname{argmin}_{T_i} H(D, T_i)$$

Redukcja danych

Entropia – miara zróżnicowania danych.

Posłużmy się przykładem. Dany jest zbiór danych D wartości atrybutu V.

Dla tego zbioru możemy wyznaczyć wektor reprezentujący częstość występowania poszczególnych wartości:

$h[] = \{8, 7, 2, 6, 9, 4\}$ <- np. $h[0] = 8$, czyli 0 występuje 8 razy

$L(D) = N = 36$, dokonajmy normalizacji $h[]/L(D) \rightarrow p()$
 $p(i) = \{8/36, 7/36, 2/36, 6/36, 9/36, 4/36\}$

Pamiętamy, że: $P1 = L(D1)/L(D)$; $P2 = L(D2)/L(D)$

Niech $T=1$, wówczas:

T=1 $P1 = 8/36$ $P2 = 28/36$ $p(1) = \{8/8\}$;

$p(2) = \{7/28, 2/28, 6/28, 9/28, 4/28\}$

$H1 = 0$; $H2 = 2,175$; $H = 8/36 * 0 + 28/36 * 2,175 = 1,691$

D:

1	2	4
1	4	4
0	4	4
0	4	4
1	4	
1	4	
0	5	
0	5	
1	5	
1	5	
0	3	
0	3	
1	3	
0	3	
0	3	
2	3	

Redukcja danych

Entropia - miara zróżnicowania danych.

T=1 $P1=8/36$ $P2=28/36$ $p(1)=\{8/8\}$; $p(2)=\{7/28, 2/28, 6/28, 9/28, 4/28\}$

$H1=0$; $H2=2,175$; $H=8/36*0+28/36*2,175=1,691$

T=2 $P1=15/36$ $P2=21/36$ $p(1)=\{8/15, 7/15\}$; $p(2)=\{2/21, 6/21, 9/21, 4/21\}$

$H1=0,996$; $H2=1,819$; $H=15/36*0,996+21/36*1,819=1,476$

T=3 $P1=17/36$ $P2=19/36$ $p(1)=\{8/17, 7/17, 2/17\}$; $p(2)=\{6/19, 9/19, 4/19\}$

$H1=1,402$; $H2=1,509$; $H=17/36*1,402+19/36*1,509=1,458$

T=4 $P1=23/36$ $P2=13/36$ $p(1)=\{8/23, 7/23, 2/23, 6/23\}$; $p(2)=\{9/13, 4/13\}$

$H1=1,864$; $H2=0,890$; $H=23/36*1,864+13/36*0,89=1,512$

T=5 $P1=32/36$ $P2=4/36$ $p(1)=\{8/32, 7/32, 2/32, 6/32, 9/32\}$; $p(2)=\{4/4\}$

$H1=2,197$; $H2=0$; $H=32/36*2,197+4/36*0=1,952$

Wynik: $T=3$, ponieważ entropia wewnątrz każdej z grup (i razem) jest najmniejsza!

Redukcja danych

Gini – miara zróżnicowania danych.

Podobną miarą charakteryzującą dynamikę wartości jest współczynnik Gini.

$$G = 1 - \sum_{k=0}^{K-1} (p(k))^2$$

Wartość współczynnika zmienia się o 0 do 1. Wartość 0 oznacza, że jest tylko jedna klasa (lub wszystkie próbki należą do jednej klasy). $G=1$ wówczas, gdy jest największe zróżnicowanie wartości próbek.

Natomiast $G=0,5$ wtedy, gdy występuje równy podział próbek dla poszczególnych wartości. Przykładem kryterium podziału mógłby być równych podział na grupy – czyli $G=0,5$.

Redukcja danych

Gini – miara zróżnicowania danych.

Wówczas:

$h[] = \{8, 7, 2, 6, 9, 4\}$ <- np. $h[0] = 8$, czyli 0 występuje 8 razy

$L(D) = N = 36$, dokonajmy normalizacji $h[]/L(D) \rightarrow p()$

$p(i) = \{8/36, 7/36, 2/36, 6/36, 9/36, 4/36\}$

Pamiętamy, że: $P1 = L(D1)/L(D)$; $P2 = L(D2)/L(D)$

Niech $T=1$, wówczas:

T=1 $P1 = 8/36$ $P2 = 28/36$ $p(1) = \{8/8\}$; $p(2) = \{7/28, 2/28, 6/28, 9/28, 4/28\}$

$G = 1 - (8/36)^2 - (28/36)^2 = 0,345679012345679$

Redukcja danych

Gini – miara zróżnicowania danych.

T=1 $P1=8/36$ $P2=28/36$ $p(1)=\{8/8\}$; $p(2)=\{7/28, 2/28, 6/28, 9/28, 4/28\}$

$G= 0,345679012345679$

T=2 $P1=15/36$ $P2=21/36$ $p(1)=\{8/15, 7/15\}$; $p(2)=\{2/21, 6/21, 9/21, 4/21\}$

$G= 0,486111111111111$

T=3 $P1=17/36$ $P2=19/36$ $p(1)=\{8/17, 7/17, 2/17\}$; $p(2)=\{6/19, 9/19, 4/19\}$

$G= 0,49845679012345673$

T=4 $P1=23/36$ $P2=13/36$ $p(1)=\{8/23, 7/23, 2/23, 6/23\}$; $p(2)=\{9/13, 4/13\}$

$G= 0,4614197530864198$

T=5 $P1=32/36$ $P2=4/36$ $p(1)=\{8/32, 7/32, 2/32, 6/32, 9/32\}$; $p(2)=\{4/4\}$

$G= 0,1975308641975309$

Wynik: T=3, ponieważ wartość wsp. gini jest najbliższy 0,5 (równy podział na grupy). Oczywiście podobnego podziału możemy dokonać analizując prosty rozkład wartości.

Redukcja danych

Wariancja – wykorzystanie do dyskretyzacji danych.

Analogicznie możemy wykorzystać wariancję jako miarę rozproszenia danych w obrębie grupy (ang. variance within):

$$var_w(D, Ti) = \frac{L(D1)}{L(D)} var_w(D1) + \frac{L(D2)}{L(D)} var_w(D2)$$

gdzie: $var_w(.)$ – wariancja wartości w grupie, $L(a)$ – liczba elementów a ;

T_i , dla którego $var_w(D, T)$ jest minimalne (najmniejsze rozproszenie w obrębie każdej grupy) jest wybierane jako optymalny próg podziału (binaryzacji):

$$argmin_{Ti}(var_w(D, Ti))$$

Redukcja danych

Wariancja – wykorzystanie do dyskretyzacji danych.

Zauważmy jednocześnie, że wariancja pomiędzy grupami (ang. variance between) może być wyrażona jako:

$$var_b(D, Ti) = var(D) - varw(D, Ti) = \frac{L(D1)}{L(D)} (\mu(D1) - \mu)^2 + \frac{L(D2)}{L(D)} (\mu(D2) - \mu)^2$$

i zakładając:

$$\mu = \frac{L(D1)}{L(D)} \mu(D1) + \frac{L(D2)}{L(D)} \mu(D2)$$

uzyskamy:

$$var_b(D, Ti) = \frac{L(D1)}{L(D)} \frac{L(D2)}{L(D)} (\mu(D1) - \mu(D2))^2$$

T_i , dla którego $var_b(D, T)$ jest maksymalna (największa różnica pomiędzy grupami) jest wybierane jako optymalny próg podziału (binaryzacji):

$$\operatorname{argmax}_{T_i}(var_b(D, T_i))$$

Redukcja danych

T=1 $P1=8/36$ $P2=28/36$, $\mu(D1) = 0$; $var_w(D1) = 0$; $\mu(D1) = (7+2*2+6*3+9*4+4*5)/28 = 3,0357$
 $N(D2)=7+2+6+9+4$

$$var_w(D2) = \left(\frac{1}{N(D2)}\right) * (1-3,0357)^2*7+(2-3,0357)^2*2+(3-3,0357)^2*6+(4-3,0357)^2*9+(5-3,0357)^2*4=1,963$$

$$var_w = 8/36 * 0 + 28/36 * (1,963) = 1,5268$$

T=2 $P1=15/36$ $P2=21/36$ $var_w = 0,5561$

T=3 $P1=17/36$ $P2=19/36$ $var_w = 0,4909$

T=4 $P1=23/36$ $P2=13/36$ $var_w = 0,9779$

T=5 $P1=32/36$ $P2=4/36$ $var_w = 2,2491$

Wynik: T=3, ponieważ wartość wariancji w ramach grup jest najmniejsza (małe zróżnicowanie wartości w grupach). **Ćwiczenie własne - obliczyć wariancję pomiędzy grupami.**

Redukcja danych

Metody redukcji wielowymiarowości bazujące na dekompozycji (rozkładzie) macierzy:

SVD - Singular Value Decomposition (lub Truncated SVD) - rozkład (dekompozycja) macierzy według wartości osobliwych; jest wykorzystywana w wielu innych metodach redukcji wielowymiarowości (np. PCA). Może być zastosowana do danych rzadkich (w przeciwieństwie do PCA).

NMF - Non-Negative Matrix Factorization - faktoryzacja (rozkład) macierzy nieujemnych - dekompozycja macierzy na dwie inne (wszystkie nieujemne)

PCA - Principal Component Analysis - analiza składowych głównych (transformacja danych (obrót), w ramach której maksymalizujemy wariancję nowej cechy numer 1 (1-sza składowa główna, 1st principal component) potem nowej cechy numer 2, itd.)

Redukcja danych

Metody redukcji wielowymiarowości bazujące na dekompozycji (rozkładzie) macierzy:

ICA - Independent Component Analysis - analiza składowych niezależnych (np. rozdzielenie sygnału użytecznego od szumu, problem: nie wiadomo, w którym komponencie jaki jest sygnał, należy stosować dodatkowe kryteria wyboru)

LDA i QDA - Linear/Quadratic Discriminant Analysis - liniowa/kwadratowa analiza dyskryminacyjna. Stosowana jako metoda klasyfikacji poszukująca takiej liniowej kombinacji zmiennych niezależnych aby uzyskać maksymalną separację klas (np. wartości średnich) i minimalną separację próbek przypisanych do klas. Redukcja wielowymiarowości polega na wyborze najbardziej różnicujących cech.

Wykorzystanie tych metody zostanie przedstawione z wykorzystaniem notatnika interaktywnego w dalszej części zajęć.

Redukcja danych

Wśród pozostałych metod należy wskazać:

- metody bazujące na modelu (np. modele regresyjne),
- metody słownikowe (np. sekwencja wartości cech tworzy pozycję w słowniku, używamy kod ze słownika w nowej reprezentacji danych),
- metody kompresji (np. w tym zastosowanie autokoderów),
- metody bazujące na osadzaniu danych (np. Isomap Embedding, Locally Linear Embedding, Stochastic Neighbour Embedding, t-SNE: t-distributed Stochastic Neighbour Embedding),
- inne metody selekcji cech, którymi zajmiemy się później.

Redukcja danych

Metody redukcji danych z wykorzystaniem modeli.

1. Przyjmowany (dopasowywany) jest model rozkładu wartości atrybutu, np. liniowy, wykładniczy, itp.
2. Zamiast danych wykorzystujemy parametry modelu.

Przykłady:

Regresja liniowa: $Y = aX + b$

Parametry a i b mogą stanowić nowy zbiór danych.

Funkcje nieliniowe: $Y = a_0 \exp(-b_0 t) + a_1 \exp(-b_1 t)$

Parametry a_0 , b_0 , a_1 , b_1 mogą stanowić nowy zbiór danych.



Przykłady – obrazowanie parametryczne w medycynie!

(Zamiast sekwencji obrazów w czasie, tworzymy obrazy parametrów modeli opisujących dynamikę zmian, np. przepływu krwi w wokselu).

Redukcja danych

Metody redukcji danych przez progowanie/grupowanie wartości.

1. Grupujemy wartości przedziałami ("paczki" histogramu)
2. Grupujemy dane za pomocą metod wydzielania klastrów (i wybieramy podzbiory)



Przykłady praktyczne (notatnik interaktywny ML_03_03_Data_Reduction)

Redukcja danych w środowisku Google Colaboratory/ Jupyter Notebook.

<https://colab.research.google.com/drive/1AeNI8zV51cB9MeTIXbWZfPHZKx9q2AoO?usp=sharing>

Plan wykładu:

- Przekształcanie danych
- Normalizacja danych
- Redukcja danych
- **Podsumowanie**

Podsumowanie - przetwarzanie wstępne

Przetwarzanie wstępne o niezwykle ważny etap i dlatego w każdym środowisku (czy API) znajdziemy bardzo dużo filtrów (funkcji) do potencjalnego wykorzystania w procesie uczenia maszynowego.



Na rysunku przedstawiono przykładowy zestaw filtrów w środowisku Weka.



POLITECHNIKA
GDAŃSKA



WYDZIAŁ ELEKTRONIKI,
TELEKOMUNIKACJI
I INFORMATYKI

Dziękuję

Jacek Rumiński



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska



Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego

Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.