



POLITECHNIKA
GDAŃSKA

AI TECH



Uczenie maszynowe

Wykład 6

Jacek Rumiński

Katedra Inżynierii Biomedycznej, Wydział ETI



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska

Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego

Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.

Plan wykładu:

- **Regresja i regularyzacja**
- Metoda gradientu prostego - wprowadzenie
- Metoda gradientu prostego - poszukiwanie parametrów
- Metoda gradientu prostego - implementacje
- Podsumowanie

Regresja

W rozwiązywaniu problemu regresji w praktyce wykorzystujemy metodę najmniejszych kwadratów (np. Non Negative Least Square – NNLS). Metodę tą stosuje np. funkcja *fit()* klasy *LinearRegression* pakietu scikit-learn.

W metodzie najmniejszych kwadratów problem optymalizacyjny polega na znalezieniu takich wartości parametrów, aby uzyskać minimum funkcji kwadratowej będącej miarą błędu (funkcją kosztu/straty), np.:

$$\hat{\theta} = \operatorname{argmin}_{\theta}(RSS_{\theta}) = \operatorname{argmin}_{\theta} \left(\sum_{i=1}^N (y_i - \hat{y}_i)^2 \right) = \operatorname{argmin}_{\theta} \left(\sum_{i=1}^N (y_i - f(x_i, \theta))^2 \right)$$

gdzie:


$f(x_i, \theta)$ – funkcja regresji (model),

x_i wektor wartości cech dla i-tej próbki (przykładu, wektora pomiarowego),

y_i – wartość referencyjna (zmienna objaśniana, kod klasy, itp.).

Regresja - regularyzacja

Pamiętajmy, że w wyniku zastosowania procedury optymalizacyjnej (np. uczenia modelu) otrzymamy model, w którym bardzo duże wartości parametrów mogą promować małe zmiany wartości cechy (zmiennnej niezależnej). Operacja regularyzacji redukuje/wyrównuje wpływ poszczególnych cech poprzez określenie dodatkowych wymagań w zakresie parametrów.



Estymator najmniejszych kwadratów jest nieobciążony, ale może prowadzić do uzyskania dużej wariancji (np. duża liczba zmiennych objaśniających, korelacja/współliniowość zmiennych). Metody regularyzacji pozwalają zredukować wariancję (czyli zmienność wyników dla różnych danych, czy kolejnych uruchomień modelu dla innych danych).

Regresja - regularyzacja

Założmy, że prawdziwy jest związek dla modelu $\mathbf{y} = \mathbf{X}\boldsymbol{\theta}$ (pomijamy błąd opisywany rozkładem normalnym o wartości średniej 0 i wariancji σ^2 ; $\mathbf{y}$, $\boldsymbol{\theta}$ - wektory, $\mathbf{X}$ - macierz).

Prawdziwe parametry $\boldsymbol{\theta}$ są nieznane. W wyniku uczenia z zastosowaniem zbioru danych $\mathbf{D}$ otrzymujemy estymacje parametrów $\hat{\boldsymbol{\theta}}(\mathbf{D})$. Możliwe jest, że dla innego zbioru danych otrzymamy inne parametry.

Naszym celem jest minimalizacja błędu średniokwadratowego:

$$\text{MSE}(\hat{\boldsymbol{\theta}}(\mathbf{D})) = E \left[\|\hat{\boldsymbol{\theta}}(\mathbf{D}) - \boldsymbol{\theta}\|^2 \right] = E \left[\|\hat{\boldsymbol{\theta}}(\mathbf{D}) - E[\hat{\boldsymbol{\theta}}(\mathbf{D})]\|^2 \right] + \|E[\hat{\boldsymbol{\theta}}(\mathbf{D})] - \boldsymbol{\theta}\|^2$$

Oznaczmy obciążenie jako $\text{Bias}(\hat{\boldsymbol{\theta}}(\mathbf{D})) = E[\hat{\boldsymbol{\theta}}(\mathbf{D})] - \boldsymbol{\theta}$, oraz wariancję jako $\text{Var}(\hat{\boldsymbol{\theta}}(\mathbf{D}))$. Ponieważ $\boldsymbol{\theta}$ i $\hat{\boldsymbol{\theta}}(\mathbf{D})$ to wektory dlatego:

$$\text{MSE}(\hat{\boldsymbol{\theta}}(\mathbf{D})) = \text{tr}[\text{Var}(\hat{\boldsymbol{\theta}}(\mathbf{D}))] + \|\text{Bias}(\hat{\boldsymbol{\theta}}(\mathbf{D}))\|^2$$

Estymator jest nieobciążony (unbiased) jeśli $E[\hat{\boldsymbol{\theta}}(\mathbf{D}) - \boldsymbol{\theta}] = \mathbf{0}$ lub inaczej ($E[\hat{\boldsymbol{\theta}}(\mathbf{D})] = \boldsymbol{\theta}$).

Regresja - regularyzacja

Analogicznie dla prawdziwego modelu $\mathbf{y} = \mathbf{X}\boldsymbol{\theta}$ oraz modelu uzyskiwanego na podstawie estymowanych parametrów $\hat{\boldsymbol{\theta}}(\mathbf{D})$ wyznaczamy predykcję wartości zmiennej zależnej $\hat{\mathbf{y}}$.

Wówczas:

$$\text{MSE}(\hat{\mathbf{y}}) = E[(\hat{\mathbf{y}} - \mathbf{y})^2] = E[\hat{\mathbf{y}} - \mathbf{y}]^2 + V[\hat{\mathbf{y}}] = (\text{Bias}(\hat{\mathbf{y}}))^2 + \text{Var}(\hat{\mathbf{y}})$$

gdzie $\text{Bias}(\hat{\mathbf{y}}) = E[\hat{\mathbf{y}} - \mathbf{y}]$. Zauważmy, że wariancja nie zależy od $\mathbf{y}$.

Dla problemu regresji liniowej możemy znaleźć związek pomiędzy obciążeniem/wariancją wyznaczoną dla estymowanych parametrów jak i dla predykcji.

Przypomnijmy, że wysoka wariancja związana jest z nadmiernym dopasowaniem modelu do danych (ang. overfitting), natomiast wysokie obciążenie występuje przy niewystarczającym dopasowaniem modelu do danych (ang. underfitting).

Oczywiście chcielibyśmy osiągnąć minimum obu wartości, ale zwykle szukamy kompromisu między wariancją i obciążeniem.

Regresja - regularyzacja

Redukcję wariancji w regresji liniowej możemy uzyskać stosując metody regularyzacji, wprowadzając dodatkowy czynnik (kary) do minimalizowanej funkcji:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left(\sum_{i=1}^N (y_i - f(x_i, \theta))^2 + \lambda \sum_{l=1}^L r(\beta_l) \right)$$

gdzie L to liczba parametrów, $r(\beta_l)$ funkcja regularyzacji dla parametru, λ - współczynnik wpływu.

Regularyzacja jest przydatna np. gdy zachodzą zależności pomiędzy zmiennymi, gdy chcemy wpływać na wybór bardziej znaczących cech (dodatkowa selekcja cech), itp.

Rodzaj regularyzacji zależy od wybranej funkcji $r(\beta_l)$.

Regresja - LASSO (Least Absolute Shrinkage and Selection Operator)

Jeśli $r(\beta_l) = |\beta_l|$ to czynnik kary stanowi suma bezwzględnych wartości parametrów:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left(\sum_{i=1}^N (y_i - f(x_i, \theta))^2 + \lambda \sum_{l=0}^L |\beta_l| \right)$$

Tak wprowadzona regularyzacja (L_1) może prowadzić do sytuacji, że niektóre parametry będą miały wartość 0 i powiązane cechy (zmienne niezależne czy objaśniające) nie będą brane pod uwagę. Oznacza to selekcję cech, a jednocześnie redukcję wpływu efektów wyboru próbek w procesie uczenia (shrinkage). Dzięki temu zabiegowi możemy uzyskać prostszy model, charakteryzujący się większą zdolnością generalizacji (mniejszy wpływ nadmiernego dopasowania ang. overfitting).

Jeśli uwzględniany jest parametr β_0 (ang. intercept) wówczas najczęściej nie podlega on modyfikacji.

Regresja - grzbietowa lub Tichonowa (ang. Ridge regression)

Jeśli $r(\beta_l) = (\beta_l)^2$ to czynnik kary stanowi suma kwadratów wartości parametrów :

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left(\sum_{i=1}^N (y_i - f(x_i, \theta))^2 + \lambda \sum_{l=1}^L (\beta_l)^2 \right)$$

Tak wprowadzona regularyzacja (L_2) może prowadzić do wyrównywania wpływu wartości (kwadratowych) parametrów modelu. Może również redukować wpływ zależności pomiędzy zmiennymi niezależnymi (regularyzacja może redukować problem z uzyskiwaniem macierzy osobliwych w przypadku operacji na macierzach).

W obu przypadkach ważną rolę pełni λ - współczynnik wpływu. Jeśli λ rośnie parametry (wagi) zmniejszają się, a wariancja maleje (dla Lasso parametry mogą osiągnąć 0 - redukcja cech - co może prowadzić do wektorów rzadkich).

Ponadto stosuje się czasami metodę elastycznej sieci (ang. elastic net), łączącą cechy obu metod regularyzacji (tj. L_1 i L_2).

Regresja - optymalizacja

Ogólnie, w celu znalezienia $\hat{\theta}$, można poszukiwać wartości poprzez sprawdzenie wszystkich możliwych kombinacji wartości parametrów („brute force” – często nierealne), poprzez zgadywanie (czy zastosowanie metody heurystycznej), poprzez wykorzystanie metody optymalizacyjnej z procedurą iteracyjną, itd.

Iteracyjne metody optymalizacyjne najczęściej:

- mają zdefiniowaną funkcję błędu (kosztu, straty),
- mają zdefiniowaną metodę poszukiwania kolejnej propozycji $\hat{\theta}$ w celu minimalizacji funkcji kosztu (np. jako zmiana poprzedniej propozycji $\hat{\theta}$),
- mają zdefiniowane warunki zakończenia poszukiwania $\hat{\theta}$.

Plan wykładu:

- Regresja i regularyzacja
- **Metoda gradientu prostego - wprowadzenie**
- Metoda gradientu prostego - poszukiwanie parametrów
- Metoda gradientu prostego - implementacje
- Podsumowanie

Metoda gradientu prostego

W celu rozwiązania problemu optymalizacji można wykorzystać szereg metod, np. Newtona, Newtona-Gaussa, gradientowe metody optymalizacji, itp. Skupimy się na zastosowaniu metod gradientowych.

Rozpatrzmy na razie prosty problem – znalezienie takiego argumentu funkcji, dla którego funkcja osiąga minimum (najlepiej globalne):

$$x_{opt} = \operatorname{argmin}_x (y(x))$$

Poszukując rozwiązania wykonalibyśmy następujące kroki:

1. ustalmy wartość początkową zmiennej $x^{[s=0]}$ (krok $s=0$, wartość $x^{[0]}$) oraz kryterium końca poszukiwania (np. liczba iteracji, minimalna zmiana funkcji kosztu, itp.),
2. sprawdźmy wartość funkcji kosztu dla $x^{[s]}$, jeśli kryterium zostało osiągnięte – koniec, inaczej:
3. Wprowadźmy zmianę: $x^{[s+1]} = x^{[s]} + \eta \cdot \Delta x$ i przejdź do 2.

gdzie: η -to krok lub współczynnik tempa/szybkości wprowadzania zmian (ang. learning rate)

Metoda gradientu prostego

Kluczowym aspektem tej metody jest sposób wprowadzania zmiany (aktualizacji) zmiennej w kolejnym kroku, czyli definicja Δx .

Poszukujemy minimum funkcji dlatego jesteśmy zainteresowani wybraniem takiego kolejnego argumentu $x^{[s+1]}$, który znajduje się w sąsiedztwie $x^{[s]}$ i prowadzi w kierunku spadku wartości funkcji czyli zmiana wartości $f(x^{[s]} + \Delta x) - f(x^{[s]})$ powinna być ujemna (dla dodatnich wartości funkcji) lub dodatnia (dla ujemnych wartości funkcji).

Dla przykładu zilustrowanego obok:


$$\Delta x = 2, \Delta f = f(4 - 2) - f(4) = 4 - 16 = -12$$

uzyskaliśmy wartość ujemną różnicy dla dodatnich wartości funkcji. Przesunęliśmy się zatem w kierunku potencjalnego minimum. Różnica "sąsiednich" wartości mogłaby określać kierunek zmian Δx .

Zauważmy, że miara wyznaczana jako:

$$\lim_{\Delta x \rightarrow 0} \frac{f(x^{[s]} + \Delta x) - f(x^{[s]})}{\Delta x}$$

to pochodna funkcji f w punkcie $x^{[s]}$.



Metoda gradientu prostego

Zaproponujemy następujący sposób wyznaczania aktualizacji parametru:

$$\Delta x = -f'(x^{[s]})$$

dla:

$$x^{[s+1]} = x^{[s]} + \eta \cdot \Delta x$$


Zgodnie z tą propozycją podążamy w kierunku spadku pochodnej (w ogólności gradientu).

Zilustrujemy to dwoma przykładami dla funkcji:

$f(x)=x^2$, $f'(x)=2x$, $\eta = 1$:

1. $x^{[0]} = 4$, $f'(x^{[0]}) = 2 * 4 = 8$, $x^{[0+1]} = 4 - 8 = -4$
2. $x^{[1]} = -4$, $f'(x^{[1]}) = 2 * -4 = -8$, $x^{[1+1]} = -4 - (-8) = 4$

W obu przypadkach „podążamy” w kierunku odwrotnym do znaku pochodnej (gradientu). Dlatego metodę to nazywa się również metodą spadku wzdłuż gradientu (ang. GD – Gradient Descent).



Metoda gradientu prostego

Zilustrujmy metodę przykładami. Załóżmy, że $f'(x) \approx (f(x+1) - f(x-1))/2$, $f(x) = x^2$ oraz $\eta = 1$.

Krok 0, $x^{[0]}=4$:

$$(x^{[0]}-1)=3 \rightarrow f(x^{[0]}-1)=3*3=9; \quad (x^{[0]}+1)=5 \rightarrow f(x^{[0]}+1)=5*5=25$$

$$f'(x^{[0]}) = (25-9)/2 = 8$$

$$x^{[1]} = x^{[0]} - 1 * f'(x^{[0]}) = 4 - 8 = -4$$

$f(-4)=16$ nie jest mniejsze od $f(4)=16$, ale spróbujmy kolejny krok:

Krok 1, $x^{[1]}=-4$:



$$(x^{[1]}-1)=-5 \rightarrow f(x^{[1]}-1)=-5*-5=25; \quad (x^{[1]}+1)=-3 \rightarrow f(x^{[1]}+1)=-3*-3=9$$

$$f'(x^{[1]}) = (9-25)/2 = -8$$

$$x^{[2]} = x^{[1]} - 1 * f'(x^{[1]}) = -4 + 8 = 4$$

$f(4)=16$ nie jest mniejsze od $f(-4)=16$. Pętla. Brak zbieżności.

Spróbujmy wykorzystać współczynnik szybkości uczenia η .



Metoda gradientu prostego

Założmy, że $f'(x) \approx (f(x+1) - f(x-1))/2$, $f(x) = x^2$ oraz $\eta =$ różne wartości.

Krok 0, $x^{[0]}=4$, $\eta = \mathbf{0,5}$ <- hiperparametr (parametr dobierany)

$(x^{[0]}-1)=3 \rightarrow f(x^{[0]}-1)=3*3=9$; $(x^{[0]}+1)=5 \rightarrow f(x^{[0]}+1)=5*5=25$

$f'(x^{[0]}) = (25-9)/2 = 8$

$x^{[1]} = x^{[0]} - 0,5 * f'(x^{[0]}) = 4 - 0,5 * 8 = 0$

$f(0)=0$ jest mniejsze od $f(4)=16$! Szczęśliwy traf!

Inny przykład: $\eta = \mathbf{0,05}$

Krok 0, $x^{[0]}=4$, $\eta = \mathbf{0,05}$

$(x^{[0]}-1)=3 \rightarrow f(x^{[0]}-1)=3*3=9$;

$(x^{[0]}+1)=5 \rightarrow f(x^{[0]}+1)=5*5=25$

$f'(x^{[0]}) = (25-9)/2 = 8$

$x^{[1]} = x^{[0]} - 0,05 * f'(x^{[0]}) = 4 - 0,05 * 8 = 3,6$

Krok 1, $x^{[1]}=3,6$, $\eta = \mathbf{0,05}$


$(x^{[1]}-1)=2,6 \rightarrow f(x^{[1]}-1)=6,76$;

$(x^{[1]}+1)=4,6 \rightarrow f(x^{[1]}+1)=21,16$

$f'(x^{[1]}) = (21,16 - 6,76)/2 = 7,2$

$x^{[2]} = x^{[1]} - 0,05 * f'(x^{[1]}) = 3,6 - 0,05 * 7,2 = 3,24$

ITD.



Przykłady praktyczne (notatnik interaktywny ML_06_01_Gradient_Descent_Var.ipynb)

Regresja w środowisku Google Colaboratory/ Jupyter Notebook.

<https://colab.research.google.com/drive/1uduJekzNu9T-1RxfQ99mesV7U0O3Oool?usp=sharing>

Plan wykładu:

- Regresja i regularyzacja
- Metoda gradientu prostego - wprowadzenie
- **Metoda gradientu prostego - poszukiwanie parametrów**
- Metoda gradientu prostego - implementacje
- Podsumowanie

Metoda gradientu prostego

Zauważmy jednak, że w celu uzyskania parametrów modelu regresyjnego nie optymalizujemy funkcji względem argumentu (zmiennnej niezależnej), lecz chcemy optymalizować RSS:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left(\sum_{i=1}^N (y_i - f(x_i, \theta))^2 \right)$$

Oznacza to, że w kolejnych krokach iteracji będziemy poszukiwać nowych, estymowanych wartości parametrów β_j , dla $j=0..L$ czyli $\theta = \{\beta_0, \beta_1, \beta_2, \dots, \beta_L\}$:

$$\beta_j^{[s+1]} = \beta_j^{[s]} - \eta \cdot \left. \frac{\partial (\mathcal{L}(X, y, \theta))}{\partial \beta_j} \right|_{\beta_j^{[s]}}$$

Dla wybranej funkcji kosztu $\mathcal{L}(X, y, \theta)$ obliczymy pochodne cząstkowe dla wszystkich parametrów uzyskując gradient (X - obserwacje dla zmiennych niezależnych, y - wartości zmiennej zależnej):

$$\nabla \mathcal{L} = \left\{ \frac{\partial \mathcal{L}}{\partial \beta_0}, \frac{\partial \mathcal{L}}{\partial \beta_1}, \frac{\partial \mathcal{L}}{\partial \beta_2}, \dots, \frac{\partial \mathcal{L}}{\partial \beta_L} \right\}$$

Metoda gradientu prostego

Zauważmy jednak, że w celu uzyskania parametrów modelu regresyjnego nie optymalizujemy funkcji względem argumentu (zmiennnej niezależnej), lecz chcemy optymalizować RSS:

$$\mathcal{L}(X, y, \theta) = k \sum_{i=1}^N (y_i - f(x_i, \theta))^2$$

gdzie: k - współczynnik skali, x_i wektor wartości cech dla i -tej próbki (przykładu, wektora pomiarowego), y_i - wartość referencyjna (zmienna objaśniana, kod klasy, itp.).

Jeśli $k=1/N$ (gdzie N - liczba próbek) to funkcja kosztu jest funkcją błędu średniokwadratowego (MSE - Mean Squared Error). Wskażmy pochodne dla założenia, że mamy dwa parametry oraz $k=1/(2N)$:

$$\frac{\partial(\mathcal{L}(X, y, \theta))}{\partial \beta_j} = \frac{\partial}{\partial \beta_j} \left(\frac{1}{2N} \sum_{i=1}^N (y_i - (\beta_0 + \beta_1 x_i))^2 \right) \quad \longrightarrow \quad \begin{aligned} \frac{\partial(\mathcal{L}(X, y, \theta))}{\partial \beta_0} &= \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i) \\ \frac{\partial(\mathcal{L}(X, y, \theta))}{\partial \beta_1} &= \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i) x_i \end{aligned}$$

$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

Metoda gradientu prostego

Dla przykładu regresji prostej (dwa parametry) aktualizacja wartości parametrów w kolejnym kroku prowadzi do:

$$\begin{aligned}\beta_0^{[s+1]} &= \beta_0^{[s]} - \eta \cdot \Delta\beta_0^{[s]} = \beta_0^{[s]} - \eta \cdot \frac{1}{N} \sum_{i=1}^N \left(y_i - (\beta_0^{[s]} + \beta_1^{[s]} x_i) \right) \\ \beta_1^{[s+1]} &= \beta_1^{[s]} - \eta \cdot \Delta\beta_1^{[s]} = \beta_1^{[s]} - \eta \cdot \frac{1}{N} \sum_{i=1}^N \left(y_i - (\beta_0^{[s]} + \beta_1^{[s]} x_i) \right) x_i\end{aligned}$$

Zauważmy, że w celu obliczenia aktualizacji $\Delta\beta_j^{[s]}$ wykorzystaliśmy wszystkie próbki w zbiorze uczącym (treningowym). Sumujemy bowiem do N , gdzie N - rozmiar zbioru treningowego.

Taka wersja metody spadku wzdłuż gradientu nazywana jest w języku angielskim: Batch Gradient Descent.

Metoda gradientu prostego

Przejsięcie algorytmu iteracyjnego przez wszystkie przykłady zbioru treningowego nazywamy jedną epoką (ang. epoch).

Metodę spadku wzdłuż gradientu możemy zaimplementować następująco:

GD (liczba_epok=E, liczba_przykładów=N):

1. dla kolejnej epoki $e < E$:
2. przemieszaź dane zbioru treningowego
3. oblicz nowe wartości parametrów stosując N przykładów
4. oblicz wartość funkcji kosztu $\mathcal{L}(X, y, \theta)$
5. jeśli kryterium końca jest spełnione zakończ inaczej przejdź do 1.

Metoda gradientu prostego

Możemy również wyobrazić sobie sytuację, że w celu aktualizacji wartości parametru wykorzystamy losowo wybraną jedną próbkę danych ze zbioru treningowego:

$$\begin{aligned}\beta_0^{[s+1]} &= \beta_0^{[s]} - \eta \cdot \Delta\beta_0^{[s]} = \beta_0^{[s]} - \eta \cdot \left(y_i - (\beta_0^{[s]} + \beta_1^{[s]}x_i)\right) \\ \beta_1^{[s+1]} &= \beta_1^{[s]} - \eta \cdot \Delta\beta_1^{[s]} = \beta_1^{[s]} - \eta \cdot \left(y_i - (\beta_0^{[s]} + \beta_1^{[s]}x_i)\right)x_i\end{aligned}$$

Taka wersja metody GD to stochastyczny spadek wzdłuż gradientu (ang. SGD - Stochastic Gradient Descent). W praktyce, w danej epoce losowo wybieramy po jednej próbce tak, aby wykorzystać wszystkie próbki zbioru treningowego (w jednej epoce). Przykładowo:

SGD (liczba_epok=E, liczba_przykładów=N):

1. dla kolejnej epoki $e < E$:
2. przemieszczaj dane zbioru treningowego
3. dla każdego kolejnego przykładu z N :
4. oblicz nowe wartości parametrów
5. oblicz wartość funkcji kosztu $\mathcal{L}(X, y, \theta)$
6. jeśli kryterium końca jest spełnione zakończ inaczej przejdź do 3 (lub 1).

Metoda gradientu prostego

Zamiast pojedynczej próbki możemy użyć podzbiór (mini-batch) o B próbkach (zwykle $B \ll N$):

$$\beta_0^{[s+1]} = \beta_0^{[s]} - \eta \cdot \Delta\beta_0^{[s]} = \beta_0^{[s]} - \eta \cdot \frac{1}{B} \sum_{i=1}^B \left(y_i - (\beta_0^{[s]} + \beta_1^{[s]} x_i) \right)$$
$$\beta_1^{[s+1]} = \beta_1^{[s]} - \eta \cdot \Delta\beta_1^{[s]} = \beta_1^{[s]} - \eta \cdot \frac{1}{B} \sum_{i=1}^B \left(y_i - (\beta_0^{[s]} + \beta_1^{[s]} x_i) \right) x_i$$

Ta wersja metody stochastycznej nazywana jest: Stochastic Mini-Batch Gradient Descent.

SMBGD (liczba_epok= E , liczba_przykładów= N , porcja= B):

1. dla kolejnej epoki $e < E$:
2. przemieszczaj dane zbioru treningowego
3. dla każdej kolejnej porcji danych B z N :
4. oblicz nowe wartości parametrów
5. oblicz wartość funkcji kosztu $\mathcal{L}(X, y, \theta)$
6. jeśli kryterium końca jest spełnione zakończ inaczej przejdź do 3 (lub 1).

Metoda gradientu prostego

Stosując metodę gradientu prostego możemy spróbować rozwiązać problem optymalizacyjny:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left(\sum_{i=1}^N (y_i - f(x_i, \theta))^2 \right)$$

Zauważmy, że wprowadzając w powyższym wzorze normalizację przez N uzyskamy:

$$\hat{\theta} = \operatorname{argmin}_{\theta} (MSE(y_i, \hat{y}_i))$$

gdzie MSE to znana nam funkcja błędu średniokwadratowego, $\hat{y}_i$ - to estymowane na podstawie aktualnego modelu wartości zmiennej zależnej.

Błąd średniokwadratowy to funkcja kwadratowa, której minimum można stosunkowo łatwo poszukiwać.

Przykłady praktyczne (notatnik interaktywny ML_06_02_Gradient_Descent_Param.ipynb)

Regresja w środowisku Google Colaboratory/ Jupyter Notebook.

<https://colab.research.google.com/drive/127dfTVEYMJIYYwOxlidJ3F0nWdWaR48K?usp=sharing>

Plan wykładu:

- Regresja i regularyzacja
- Metoda gradientu prostego - wprowadzenie
- Metoda gradientu prostego - poszukiwanie parametrów
- **Metoda gradientu prostego - implementacje**
- Podsumowanie

Metoda gradientu prostego - implementacje

Zaprezentowane wcześniej przykłady w interaktywnych notatnikach bazowały na wyznaczeniu gradientu stosując dwa różne podejścia:

- a) na podstawie wzoru (czyli wiedzieliśmy jaka jest postać pochodnej i mogliśmy zaprogramować ją jako funkcję),
- b) na podstawie obliczeń symbolicznych.

W praktyce uczenia maszynowego najczęściej wykorzystuje się metody numeryczne do wyznaczania gradientu funkcji.

Przykładowo w popularnym pakiecie TensorFlow (<https://www.tensorflow.org>) stosuje się specjalną klasę o nazwie *GradientTape*, której obiekt najpierw "śledzi" operacje na danych (tensorach), a następnie umożliwia obliczenie wartości gradientów (poprzez funkcję `gradient()`).

Omówiono to w kolejnym notatniku interaktywnym.

Przykłady praktyczne (notatnik interaktywny ML_06_03_Gradient_Descent_TF.ipynb)

Regresja w środowisku Google Colaboratory/ Jupyter Notebook.

https://colab.research.google.com/drive/1VR-_Y_sJEp6tQ_Yxwwb24M5oKZMp57ZP?usp=sharing

Metoda gradientu prostego - implementacje

Rozwój bibliotek programistycznych dla potrzeb uczenia maszynowego spowodował, że znaczna część operacji niskiego poziomu jest ukrywana przed użytkownikiem. Specjalista uczenia maszynowego najczęściej będzie korzystał z bibliotek wysokiego poziomu takich jak np. Keras w środowisku TensorFlow.

Keras (<https://keras.io>) dostarcza interfejs programistyczny, który umożliwia skupienie się na praktycznym wykorzystaniu zaimplementowanych metod pisząc jak najmniej własnego kodu źródłowego. Obecnie, prawdopodobnie najczęściej Keras jest wykorzystywany w pracach z głębokimi sztucznymi, sieciami neuronowymi. Nie oznacza to jednak, że nie jest stosowany do innych modeli uczenia maszynowego.

W kolejnym interaktywnym notatniku podano proste zastosowanie Keras API w problemie poszukiwania parametrów modelu regresji liniowej.

Przykłady praktyczne (notatnik interaktywny ML_06_04_Gradient_Descent_Keras.ipynb)

Regresja w środowisku Google Colaboratory/ Jupyter Notebook.

<https://colab.research.google.com/drive/1yRy22iEfVr5mcOaTgvk367q9kO5LFTif?usp=sharing>

Plan wykładu:

- Regresja i regularyzacja
- Metoda gradientu prostego - wprowadzenie
- Metoda gradientu prostego - poszukiwanie parametrów
- Metoda gradientu prostego - implementacje
- **Podsumowanie**

Podsumowanie

Po zapoznaniu się z metodami regresyjnymi oraz algorytmem optymalizacji zdobyliśmy podstawy do zapoznania się z bardziej zaawansowanymi zadaniami uczenia maszynowego.

Zauważmy, że definicja linii, płaszczyzny czy hiperpłaszczyzny jakie moglibyśmy uzyskać w regresji mogłyby być wykorzystane do separacji wektorów pomiarowych w przestrzeni cech. Oznacza to, że moglibyśmy zaadaptować metody regresji do problemu klasyfikacji danych.

Ciekawym zastosowaniem regresji będzie przypadek, gdy zmienna zależna (objaśniana) y nie jest ciągła, a np. przyjmuje wartości 0 lub 1, czyli dokładnie jak dla klasyfikacji binarnej. Wówczas, przy spełnieniu określonych założeń, będzie można zastosować model regresji logistycznej, od którego rozpoczniemy kolejny cykl wykładów skupiony na klasyfikacji danych.



POLITECHNIKA
GDAŃSKA

AI TECH



Dziękuję

Jacek Rumiński



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska

Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego

Program Operacyjny Polska Cyfrowa na lata 2014-2020.

Oś priorytetowa nr 3 „Cyfrowe kompetencje społeczeństwa”, działanie nr 3.2 „Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej”.

Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”.